

超越黑箱：建構台灣新聞語境下之高解釋性與高準確率假新聞檢測人機協作系統

後設資料

想法編號: seed-theory-5=>2=>3=>2

新穎度: 20.9%

最大相似度: 79.1% (近似於: “Exploring Artificial Intelligence Technologies for Fake News Detection”)

群集: 3

競賽得分: 4 勝

方法論契合度: 5/5

Methodology Reasoning: Directly extends the target’s fake news detection experiment by improving model accuracy and adding explainable AI and user testing. The methodology (model comparison, feature engineering, user experiments) fully aligns with the target’s focus on AI technology adoption and trust in Taiwan news.

問題陳述

在台灣，假新聞的氾濫已對社會信任、民主政治及公共衛生造成嚴重威脅。儘管現有研究已運用人工智慧（AI）技術，如深度學習模型，在假新聞檢測上達到高準確率（例如目標論文中的 90.53%），但這些模型多為「黑箱」系統，使用者無法理解其決策邏輯，導致信任度不足、誤用風險增加。尤其在新聞語境中，假新聞往往混雜繁體中文、台語、英語等混合語言，並融入台灣特有的社會文化脈絡（如政治敏感詞、網路迷因），使得通用模型難以精準判讀。此外，現有系統缺乏有效的人機協作機制，無法讓使用者（如記者、編輯、讀者）在接收檢測結果時，能夠依據解釋訊息進行理性判斷，進一步調整新聞共享行為。因此，本研究的核心問題是：如何開發一個針對台灣新聞語境、兼具高解釋性與高準確率的假新聞檢測系統，並透過人機協作介面提升使用者的信任、降低認知負荷，從而有效遏止假新聞的傳播？這個問題的重要性在於，它不僅能提升 AI 技術在實務中的應用性，更能深化對 AI 如何輔助而非取代人類判斷的理解，為台灣社會提供一個透明、可靠的假新聞防制工具。

現有方法

現有的假新聞檢測方法主要分為幾大類：特徵工程方法（如 TF-IDF、SVM、XGBoost）、深度學習方法（如 BERT、LSTM）以及混合模型。在台灣研究脈絡下，目標論文（人工智慧科技在臺灣新聞傳播領域之運用與發展）已使用 AI 訓練假新聞辨識模型，達到 90.53% 正確率，但該模型缺乏可解釋性，且未針對台灣語言與文化特徵進行優化。其他相關研究，如 Fake News Detection Algorithms Comparison（比較 XGBoost、SVM、NB）和 A comprehensive review of fake news detection（強調特徵工程與融合），雖提出改進方向，但多著重於通用數據集（如國際英文新聞），對台灣在地性語境（如混雜語言、社會文化參照）的適應性不足。XFlag 等可解釋模型雖然引入 Layer-wise relevance propagation (LRP)，但未整合人機協作介面，且在中文語境下的應用仍有限。此外，現有系統多為靜態輸出（如標籤或分數），缺乏動態解釋機制，無法讓使用者根據自身需求進一步探索決策依據。這些限制導致高準確率模型在實務中難以被信任與採用，因為使用者無法判斷何時該依賴模型、何時該保留判斷。

研究動機

現有方法之所以不足，核心在於它們過度追求預測效能，而犧牲了可解釋性與人機協作。在台灣新聞語境中，假新聞的判斷往往涉及複雜的社會文化因素（如政治立場、地方習俗），這些無法僅靠模型的黑箱輸出解決。例如，一個模型可能將某篇帶有批判性政治言論的新聞標記為假，但實際上它只是立場鮮明的事實報導；若缺乏解釋，使用者可能誤信或誤判。因此，我的動機是從認知科學與人機互動理論出發，結合 Situation awareness-based agent transparency (SAT) 模型，設計一個能讓使用者「參與」決策

過程的系統。SAT 模型強調讓 AI 系統透明化其目標、推理過程與預測結果，使使用者能同步理解系統的運作狀態。我將此與可解釋 AI 技術（如 LRP）結合，不僅生成解釋向量，還將其轉化為視覺化、層級化的資訊，呈現在人機介面上。如此一來，使用者可以檢視新聞中哪些詞彙、句子或引用來源導致模型判斷為假，並根據自身專業知識進行驗證或反思。這種協作模式能提升信任度、減少認知負荷（因為系統提供結構化解釋），並促進使用者在新聞共享前的謹慎行為。此外，透過整合台灣在地語料庫（如 CoFacts、PTT 新聞板塊），並引入特徵工程（如 TF-IDF 與深度學習特徵融合），我預期能超越 90.53% 的準確率，同時保持高解釋性。這個方法之所以能成功，是因為它回應了使用者對透明度的需求，並利用了台灣社會對假新聞議題的高度關注。

提出方法

本方法旨在建構一個「可解釋假新聞檢測人機協作系統」，分為三大模組：特徵工程與模型訓練模組、可解釋性生成模組、以及人機協作介面模組。

模組一：特徵工程與模型訓練模組 1. **數據蒐集與預處理**：從台灣新聞平台（如 Yahoo 奇摩新聞、ETtoday、自由時報）、社群媒體 PTT、以及公開假新聞資料庫（如 CoFacts、台灣事實查核中心）蒐集繁體中文新聞文本，並標註真假標籤。另蒐集混合語言樣本（如台語羅馬字、英文術語）以增強模型對在地語境的適應性。2. **特徵工程**：進行多層次特徵提取。- 詞彙層級：使用 TF-IDF、詞嵌入（Word2Vec）、以及 BERT 預訓練詞向量。- 句法層級：分析句法結構（如依存句法）、情感極性（使用台灣情感詞典，如 NTUSD）。- 語用層級：計算引用來源可信度分數（基於來源媒體歷史）、以及社會文化參照（如提及政治人物、地方事件）。- 融合特徵：將上述特徵透過注意力機制（attention mechanism）融合，形成高維度特徵向量。3. **模型訓練與比較**：訓練多個模型，包括 XGBoost、BERT（繁中版，如 BERT-base-chinese）、以及混合模型（如 XGBoost+BERT）。使用 10-fold 交叉驗證進行超參數調優，並以準確率、精確率、召回率、F1 分數評估。目標是超越 90.53% 準確率。

模組二：可解釋性生成模組 1. **解釋向量生成**：使用 Layer-wise relevance propagation (LRP) 對訓練好的深度學習模型進行解釋。LRP 會將預測結果反向傳播，計算每個輸入特徵（如詞彙、句子）對最終決策的貢獻度。輸出為一組解釋向量，標示哪些部分最關鍵。2. **解釋結構化**：將解釋向量轉化為層級結構，例如：第一層顯示新聞整體可信度（高/中/低），第二層細分為「內容事實」、「來源可靠性」、「語言風格」等維度，第三層則突出具體詞句。3. **適應性解釋**：根據使用者角色（記者、編輯、一般讀者）調整解釋層級。例如，記者可能需要詳細的來源分析，而讀者只需簡潔警示。

模組三：人機協作介面模組 1. **基於 SAT 模型的介面設計**：介面分為三區：- **目標區**：顯示 AI 的檢測目標（如「判斷此新聞是否為假」）以及其信心水平。- **推理區**：使用圖形化方式（如熱力圖、條形圖）呈現 LRP 生成的解釋，標示關鍵詞句與貢獻度。例如，若模型認為新聞中「大量引用匿名來源」是可疑的，該句會被高亮。- **互動區**：允許使用者點擊關鍵詞句，查詢原始資料或延伸資訊（如來源媒體的歷史可信度）。使用者也可回饋意見（如標記錯誤判斷），系統將據此進行在線學習（online learning）更新模型。2. **認知負荷管理**：透過眼動實驗優化介面布局，確保重要資訊（如解釋）能在短時間內被使用者捕捉。3. **共享行為干預**：在使用者點讚或分享前，介面會跳出簡短提示（如「此新聞被 AI 判定為可疑，您是否要查看解釋？」），鼓勵反思。

此方法的獨特性在於首次將 LRP 與 SAT 模型整合於台灣新聞語境，並結合使用者反饋進行動態學習，實現「人類在迴路中」（human-in-the-loop）的協作模式。

實驗計畫

實驗分為三階段，每階段有明確步驟與評估指標。

第一階段：模型效能驗證 1. **數據集**：使用 CoFacts 資料庫（約 10 萬條台灣新聞+查核結果）、自行蒐集之 PTT 新聞板塊（約 5 萬條）、以及台灣事實查核中心資料（約 2 萬條）。隨機分割為訓練集（70%）、驗證集（15%）、測試集（15%）。2. **基線模型**：XGBoost（僅 TF-IDF 特徵）、BERT（繁中版，微調）、以及目標論文中的模型（若可複現，則以 90.53% 為基線）。3. **評估指標**：準確率、精確率、召回率、F1 分數、AUC-ROC。4. **步驟**：- 步驟 1：預處理數據，包括分詞（使

用 CKIP 或 Jieba)、去除停用詞、標註標籤。- 步驟 2：分別訓練所有基線模型，記錄效能。- 步驟 3：實施本研究的特徵工程與混合模型 (XGBoost+BERT)，進行 10-fold 交叉驗證。- 成功標準：混合模型在測試集上準確率超過 92%，且 F1 分數優於所有基線。

第二階段：可解釋性評估 1. **數據集**：從測試集中隨機抽取 500 則新聞 (250 真實、250 假)，每則生成 LRP 解釋向量。2. **評估指標**：解釋忠誠度 (faithfulness，即解釋是否反映模型真實決策)、解釋穩定性 (stability，即對相似輸入是否產生一致解釋)。3. **步驟**：- 步驟 1：對每則新聞運行 LRP，生成詞級貢獻度。- 步驟 2：人工評審 (邀請 3 位台灣新聞傳播領域專家)，對解釋的合理性進行 1-5 分評分。- 步驟 3：與現有可解釋模型 (如 LIME、SHAP) 比較忠誠度與穩定性。- 成功標準：LRP 解釋的忠誠度得分高於 LIME 與 SHAP，且專家評分平均高於 4 分 (滿分 5)。

第三階段：人機協作使用者實驗 1. **受試者**：招募 60 名台灣大學生與研究生 (30 名新聞傳播相關系所，30 名非相關)，隨機分為實驗組 (使用本系統) 與對照組 (使用無解釋的傳統 AI 檢測系統)。2. **實驗任務**：每位受試者需在 15 分鐘內閱讀 10 則新聞 (5 真實、5 假)，並決定是否分享。實驗組介面具解釋與互動功能；對照組僅顯示「真/假」標籤。3. **工具與指標**：- 眼動儀 (如 Tobii Pro)：記錄凝視時間、回訪次數，以評估認知負荷。- 問卷：採用標準化量表 (如信任量表、系統可用性量表 SUS)。- 行為指標：分享準確率 (正確分享真實新聞、避免分享假新聞的時間與比例)。4. **步驟**：- 步驟 1：受試者填寫前測問卷 (媒體素養、信任傾向)。- 步驟 2：進行實驗任務，眼動儀記錄全程。- 步驟 3：任務後填寫後測問卷 (信任度、認知負荷、系統評價)。- 成功標準：實驗組在信任度、分享準確率上顯著高於對照組 ($p < 0.05$)，且在認知負荷指標 (如平均凝視時間) 上顯著低於對照組。此外，眼動數據應顯示實驗組對解釋區域有較高的關注。

預期成果若實驗成功，本研究將提供一個兼具高準確率 ($>92\%$) 與高解釋性的台灣假新聞檢測系統，並證實人機協作介面能提升使用者信任與正確共享行為。此系統可直接應用於新聞室、社群平台，或作為媒體素養教育工具。

可信新穎度 — 最接近的真實論文

- Exploring Artificial Intelligence Technologies for Fake News Detection (79.1% · airiti.AL, 2021) — 高度重疊：該論文主要比較人類與電腦在中文假新聞偵測上的表現，使用 Naïve Bayes、SVM、BERT 等模型進行分類，但未涉及可解釋性技術 (如 LRP) 或人機協作介面的設計。本提案則專注於建構高解釋性的假新聞檢測系統，並透過人機協作介面提升使用者信任與降低認知負荷，核心差異在於從「模型效能比較」轉向「可解釋性與人機協作系統的開發」。(相似度 79% 偏高，標籤經相似度守衛下修)
- Empirical Research on Fake News Detection Using AI Technology (71.8% · airiti.AL, 2021) — 增量：該論文運用 AI 與深度學習方法設計新聞可信度評估系統，達到 90.53% 準確率，但僅提及 AI 決策可解釋性為需深思的問題，未實際開發可解釋性模組或人機協作機制。本提案不僅要超越此準確率，更核心的是建構 LRP 解釋向量生成與結構化解釋，並設計人機協作介面，從「高準確率模型」延伸至「可解釋且可協作的系統」。
- The Application and Development of Artificial Intelligence in Taiwan's News Communication (71.3% · airiti.AL, 2021) — 增量：該論文探討 AI 在台灣新聞傳播領域的應用，包括假新聞辨識模型 (正確率 90.53%)，但重點在於分析 AI 對媒體信任與社會真實的侵蝕，而非開發可解釋性技術或人機協作系統。本提案則聚焦於技術開發，透過 LRP 生成解釋向量並設計人機協作介面，以解決黑箱問題，研究問題從「社會影響分析」轉向「系統建構與評估」。(相似度 71% 偏高，標籤經相似度守衛下修)

參考文獻

1. Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan's Newsrooms

2. Fake News Detection Algorithms Comparison and Application of XGBoost, SVM, and NB
3. A comprehensive review of fake news detection on social media: feature engineering, feature fusion, and future research directions
4. XFlag: explainable fake news detection model on social media
5. Exploring Artificial Intelligence Technologies for Fake News Detection
6. Empirical Research on Fake News Detection Using AI Technology
7. AI, Newsroom Automation, and the Configuration of News in Transformation
8. Crowdfunding Journalism in Taiwan:The case study of weReport
9. Anthropomorphic Analysis of Chinese News: A Case Study on Artificial Intelligence Discourse
10. Exploring the Impact of Chatbots with Anthropomorphism and Empathy on the Continuance Intention
11. Exploring the Antecedents and Effects of Taiwanese Users' Adoption of AI Technologies
12. Framing the Pandemic: An Analysis of COVID-19 News Reports in Taiwanese Media
13. (Re-)framing Political Discourse in News Translation
14. Analyzing the impact of sentiment in financial community articles on the stock market using generative AI
15. A Study on News Media Image of Libraries in Taiwan
16. Analyzing Media Frames and Comments on the Hong Kong Immigration Wave to Taiwan Using Artificial Intelligence
17. The Effect of Anthropomorphic Presentation of Voice Assistants on User Trust and Behavior
18. Research on Risk Perception and Usage Behavior of AI-assisted Driving Systems: Taking Tesla as an Example
19. The Practice of Health Self-management in the AI Era
20. A Study on the Factors Influencing Behavior of LINE Bot as an Assistive Healthcare Tool
21. The Application and Development of Artificial Intelligence in Taiwan's News Communication
22. The impact of artificial intelligence news source credibility identification system on the effectiveness of media literacy education
23. E-hand News
24. Exploring the Effect of Fake News Characteristic Markings on the Perceived Credibility of Readers with Different Cognitive Style in Fake News
25. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
26. 人工智能在美國新聞業的應用與影響

27. 從”人機協同”看人工智慧時代的新聞倫理建構
28. 媒體可信度研究：起源，發展，機會和挑戰
29. 人工智能對新聞業影響的對策分析
30. 汪志堅 | AI 深度學習與假新聞偵測
31. 數據新聞：大數據時代新聞可視化傳播的創新路徑
32. 大數據與新聞報導
33. 大數據方法與新聞傳播創新：從理論定義到操作路線
34. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
35. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
36. 再論後真相：基於時間與速度的視角
37. Post-truth，後真相的真相
38. 誰帶風向：被金錢操弄的公共輿論戰爭
39. 不是臺灣獨有- 大選假新聞成全球流行病

從被動回應到主動預防：一個結合 AI 即時偵測與遊戲化激勵的使用者中心事實查核平台設計與實證研究

後設資料

想法編號: seed-domain-5=>2=>3=>3

新穎度: 46.0%

最大相似度: 54.0% (近似於: “Empirical Research on Fake News Detection Using AI Technology”)

群集: 0

競賽得分: 3 勝

方法論契合度: 3/5

Methodology Reasoning: Develops a mobile app integrating the target’s model and a retrieval system, with a field experiment tracking usage and trust. This aligns with AI application and trust analysis, but the design is more product-oriented and introduces theoretical frameworks (TPB) not in the target paper.

問題陳述

在臺灣，假訊息的快速流竄已對民主社會、公共衛生與食品安全造成嚴重威脅。儘管第三方事實查核中心（如台灣事實查核中心）與社群媒體平台已投入大量資源進行查核與標示，但現有機制多為被動回應——使用者必須主動提交可疑訊息或等待查核報告發布，導致許多假訊息在查核前已廣泛傳播。此外，現有事實查核研究（如探討計劃行為理論的文獻）發現，知覺行為控制（perceived behavioral control）是促進民眾使用查核平台的最強正向因素，但如何有效提升此控制感仍缺乏系統性設計。同時，使用者可能因過度信任查核結果（over-trust）而減少主動查核行為，或因查核過程繁瑣而放棄。更重要的是，臺灣存在顯著的城鄉數位落差與世代差異（如樂齡長者較易受假訊息影響），但現有平台與課程多未能針對這些異質性進行個人化設計。因此，本研究的核心問題是：如何透過一個整合 AI 即時偵測、個人化推播與遊戲化激勵的行動平台，有效提升不同背景使用者的知覺行為控制與適度信任感，從而促進其主動查核行為，並減少假訊息的影響？此問題的重要性在於：若成功，將從根本改變事實查核的被動模式，建立一個可持續、可擴展的預防機制，並為臺灣社會的媒體素養教育提供實證基礎。

現有方法

現有事實查核方法主要分為三類。第一類是第三方人力查核，如台灣事實查核中心、MyGoPen 等組織，依賴專家與志工進行驗證，但該模式因人力有限而無法即時回應大量訊息，且處於被動等待舉報的狀態（如 CORPS 模型研究所述）。第二類是自動化事實查核系統，包括目標論文提出的 AI 假新聞辨識模型（正確率 90.53%）以及無監督事實查核檢索模型（Unsupervised Fact-checking Retrieval Model），這些系統能快速比對訊息與資料庫，但多停留在後端技術開發，缺乏與使用者互動的介面設計。第三類是教育介入方案，如針對樂齡長者設計的事實查核課程（如數位媒體素養課程研究），雖然能提升查核技能，但課程時間有限且脫離日常資訊接收情境，難以養成長期習慣。此外，現有研究（如 Exploring Fact-Checking Behavior）多使用橫斷面問卷調查，缺乏對實際使用行為的長期追蹤。主要限制在於：1) 技術與使用者行為脫節，AI 模型未被整合到使用者易於使用的工具中；2) 缺乏動機設計，無法解決查核行為的動機低落問題；3) 忽略使用者的異質性，未針對不同人口特徵進行適配。

研究動機

現有方法之所以不足，是因為它們分別處理技術、行為或教育層面，卻未將三者整合到一個統一的平台中。例如，AI 模型雖然準確率高，但若使用者不知道如何使用或缺乏查核動機，則模型僅是學術成果；而教育課程雖能提升意願，但脫離實際訊息接觸的即時性。本研究的靈感來自於兩個關鍵發現：第一，計劃行為理論研究指出知覺行為控制是預測查核行為意圖的最強因子，而控制感可透過設計易用、即時的工具來提升；第二，遊戲化設計（如獎勵、進度追蹤）已被證實能有效提高健康行為的持續性，但尚未被應用於事實查核。因此，我們提出一個「主動預防」而非「被動回應」的範式轉移：透過 AI 模型即時偵測可疑訊息，並以推播通知主動觸發使用者，降低查核的啟動成本；同時引入遊戲化機制（如積分、排行榜、虛擬徽章）來解決動機問題，並根據使用者過往行為動態調整難度，避免過度信任或疲勞。此方法預計會比現有被動查核平台更有效，因為它直接作用於使用者最常接觸訊息的時刻，並將查核行為內化為日常習慣。

提出方法

本方法提出一個名為「FactGuard」的行動應用程式，其核心設計包含三個層次：AI 偵測層、推播與摘要層、以及遊戲化激勵層。

****整體概述****：FactGuard 首先整合目標論文訓練的 AI 假新聞辨識模型（正確率 90.53%）與無監督事實查核檢索模型，作為後端引擎。當使用者手機接收到任何來自社群媒體（如 LINE、Facebook）或新聞網站的訊息時，應用程式會後台截取（經使用者授權）或允許使用者手動貼入，AI 模型立即進行真偽判斷，並在 3 秒內返回結果。若判定為「高風險假訊息」，系統會自動生成簡短摘要（約 50 字）與可信來源連結，並透過推播通知使用者。為避免過度干擾，系統會根據使用者歷史查核行為（如查核頻率、正確率）動態調整推播頻率——對於經常查核的使用者減少推播，對於很少查核的使用者則增加推播。遊戲化層面則包括：每次查核可獲得「查核積分」，連續查核 7 天可獲得「連續徽章」，並設有每週排行榜（可選擇匿名或公開），積分可兌換如超商禮券或捐贈給事實查核組織的虛擬貨幣。

****步驟詳解****：1. ****AI 模型整合與調校****：基於目標論文提供的訓練好的模型（使用新聞傳播領域數據），進一步微調以適應即時推播場景。同時整合無監督檢索模型，使其能比對超過 50 萬筆已驗證訊息資料庫。2. ****使用者註冊與分層****：使用者首次使用時填寫基本人口背景（年齡、居住地、教育程度、媒體使用習慣），系統將其歸入「城鄉/世代」分層，並根據此分層決定初始推播頻率（例如樂齡長者每 2 小時一次，年輕族群每 4 小時一次）。3. ****訊息截取與判斷****：使用者可授權應用程式讀取剪貼簿或通知欄內容，或手動輸入訊息。AI 模型輸出真偽機率（0-1），若 >0.8 則標示為「高度可疑」， $0.5-0.8$ 為「中度可疑」， <0.5 為「可信」。4. ****推播與摘要生成****：對於高度可疑訊息，系統使用自然語言生成技術（可參考目標論文中的生成方法）自動產生簡短摘要，例如：「☐ 您收到的訊息『鹽水漱口可殺死新冠病毒』經查證為錯誤資訊。正確做法：使用清水漱口即可。點此查看完整查核報告。」摘要後附有「立即查核」按鈕，點擊後顯示詳細比對結果。5. ****遊戲化機制****：每次查核（包含查看報告、分享給他人、或手動標記訊息為可疑）獲得 10-50 點積分。連續 7 天每天至少查核一次獲得「查核達人」徽章。每週六晚間公布該週積分前 10% 的使用者，給予額外獎勵點數。積分可兌換為實體獎勵（如超商商品卡）或捐贈給台灣事實查核中心。6. ****動態調整演算法****：系統記錄每位使用者的查核行為（查核次數、正確判斷比率、推播點擊率），每週運行一次調整模型：若使用者點擊率低於 20%，則降低推播頻率 50%；若使用者連續 3 天未查核，則發送一次「您有未查核的訊息」提醒。

此方法與現有技術的最大差異在於其主動性與個人化：現有查核 App（如 Cofacts）多為被動輸入查詢，而 FactGuard 從訊息接收端即介入，並透過遊戲化與動態調整解決動機與疲勞問題。

實驗計畫

實驗將採用縱貫性田野隨機對照試驗（RCT），為期 12 週，分為三個階段：預試（第 1-2 週）、正式干預（第 3-10 週）、追蹤（第 11-12 週）。

****步驟 1：參與者招募與分層**** - 透過網路廣告與實體據點（如社區大學、農會、里長辦公室）招募 500 名參與者，年齡 18 歲以上，涵蓋北/中/南/東/離島地區，並確保 20% 為 65 歲以上樂齡者。 - 使

用問卷收集人口變項、媒體素養、基線查核行為與信任感（採用 Likert 量表，如「我認為事實查核平台是可靠的」）。- 隨機分派為兩組：控制組（250 人，僅接收被動查核報告，無推播與遊戲化）與實驗組（250 人，使用完整 FactGuard 功能）。

****步驟 2：應用程式部署與訓練**** - 開發 iOS 與 Android 版本 FactGuard，後端串接目標論文的 AI 模型與無監督檢索模型（使用 Python Flask API）。- 所有參與者安裝應用程式，控制組只看到被動查核報告（需手動輸入訊息），實驗組看到完整介面。- 第 1 週進行使用教學，並讓參與者熟悉介面。

****步驟 3：數據收集**** - ****系統日誌****：記錄每次查核時間、查核內容、AI 判斷結果、使用者行為（點擊、分享、手動輸入）。- ****每週問卷****：使用中文版計劃行為理論量表測量知覺行為控制、態度、主觀規範；使用信任量表測量能力信任、關懷信任；並詢問「本週您是否因看到推播而查核了至少一次訊息？」。- ****第 12 週後測問卷****：重複測量上述變項，並加入「對平台整體使用經驗」的開放式問題。

****步驟 4：評估指標與成功標準**** - ****主要指標****：全期平均每週查核次數（實驗組 vs 控制組）。成功標準：實驗組平均每週查核次數顯著高於控制組（效應量 Cohen's $d > 0.5$ ）。- ****次要指標****：知覺行為控制分數提升幅度（前後測比較）、信任感適中化（過度信任者比例下降 20%）、假訊息接觸後查核率（透過問卷自陳）。- ****探索性分析****：城鄉分層（都市/鄉鎮）與世代（18-40 歲/41-64 歲/65 歲以上）的調節效果。

****步驟 5：統計分析**** - 使用重複測量變異數分析（RM-ANOVA）比較組間與組內變化。- 使用結構方程模型（SEM）檢驗「遊戲化使用→知覺行為控制→查核行為」的中介路徑。

****預期成功結果****：實驗組的查核頻率達到每天至少 1 次（相較控制組每週 1 次），且知覺行為控制平均分數提升 1 個標準差以上。若結果顯著，將證明主動推播與遊戲化設計能有效改變事實查核行為，並可作為未來政策推廣的依據。

可信新穎度 — 最接近的真實論文

- Empirical Research on Fake News Detection Using AI Technology (54.0% · airtiti.AL, 2021) — 區隔明確：該論文專注於開發 AI 假新聞偵測模型（辨識率 90.53%），並討論 AI 決策的可解釋性與社會依賴問題，但未涉及使用者行為改變或平台設計。本提案則進一步將該 AI 模型整合至行動應用程式中，並加入遊戲化激勵、個人化推播與縱貫性 RCT 實驗，以實證方式探討如何提升使用者的知覺行為控制與主動查核行為，這是該論文完全未觸及的範疇。
- A comprehensive review of fake news detection on social media: feature engineering, feature fusion, and future research directions (53.8% · airtiti.AL, 2023) — 區隔明確：該論文為文獻回顧，系統性整理社群媒體假新聞偵測的特徵工程與特徵融合技術，但未提出任何實證研究或使用中心設計。本提案則基於現有技術，進一步設計一個整合 AI 偵測、遊戲化激勵與個人化推播的行動平台，並透過田野 RCT 驗證其對使用者行為的影響，兩者在研究問題（技術回顧 vs. 行為干預）與方法（文獻綜述 vs. 實證實驗）上有根本差異。
- Exploring Artificial Intelligence Technologies for Fake News Detection (47.8% · airtiti.AL, 2021) — 區隔明確：該論文探討人類與電腦在中文假新聞偵測上的表現，包括使用 Naïve Bayes、SVM、BERT 等模型進行分類，以及人類辨別假新聞的實驗，但重點在於比較人機偵測能力，而非設計使用者中心平台或改變查核行為。本提案則以該論文可能使用的技術為基礎，進一步建構一個整合即時偵測、推播與遊戲化的行動應用，並聚焦於提升不同背景使用者的主動查核動機與行為，兩者的核心研究問題（人機比較 vs. 行為干預）與方法（分類實驗 vs. 縱貫性 RCT）截然不同。

參考文獻

1. When False Claims Take Root Do Corrections Matter? A Preliminary Study on Third-Party Fact-Checking Mechanisms

2. The effects of fact-check courses on fact-checking skills and misinformation detection in older adults
3. Exploring Fact-Checking Behavior: A Case Study on Food Safety Message
4. Factors and their effects of precautionary measures and fact-checking behavior toward food-safety misinformation
5. A Study on Operation and Management of Taiwan FactCheck Center Based on CORPS Model
6. Integrating Digital Media Literacy into Courses for Older Adults: An Analysis of Instructors' Perspective
7. Unsupervised Fact-checking Retrieval Model : A Real Case Study
8. Content Characteristics and Verification Strategies of Fake News about COVID-19— A Case Study of the Taiwan Fact-Check Center
9. Prevention of fakes news can learn from the COVID-19's control experience in Taiwan
10. Exploring the Linguistic Style Disparities between AI-generated and Manually Written Fact-check Reports: A Case Study on COVID-19 Fake News
11. Claim Detection in Tweets
12. Whom Are News Bots " Laboring " for? Effects of Automated Journalism on Journalists
13. The Application and Development of Artificial Intelligence in Taiwan's News Communication
14. An Exploratory Study of Development and Usage of an Artificial Intelligence Identification System of News Source Credibility
15. Understanding Important Language Features of Fake News: Word Patterns as Neural Networks Inputs
16. Report on the APAC Trusted Media Summit 2023
17. Validating the effectiveness of fact-check alerts
18. 從歐盟、澳洲經驗探討我國假訊息治理議題
19. Media Literacy in an age of Artificial Intelligence: An exploratory research from HMC
20. Smart Web Generator based on Artificial Intelligence and Web Crawler Techniques
21. The Wandering Truth: Media Representation about " Human and Artificial Intelligence " and Its Discourse, Political and Economic Criticism
22. The Balancing Approach as a Way of Thinking about the Ethics of News Reporting
23. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
24. 人工智能在美國新聞業的應用與影響
25. 從" 人機協同 " 看人工智慧時代的新聞倫理建構

26. 媒體可信度研究：起源，發展，機會和挑戰
27. 人工智能對新聞業影響的對策分析
28. 汪志堅 | AI 深度學習與假新聞偵測
29. 數據新聞：大數據時代新聞可視化傳播的創新路徑
30. 大數據與新聞報導
31. 大數據方法與新聞傳播創新：從理論定義到操作路線
32. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
33. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
34. 再論後真相：基於時間與速度的視角
35. Post-truth，後真相的真相
36. 誰帶風向：被金錢操弄的公共輿論戰爭
37. 不是臺灣獨有- 大選假新聞成全球流行病

設計政治適應性的事實查核系統：議題類型與使用者意識形態如何調節 AI 生成糾正資訊在台灣的效果

後設資料

想法編號: seed-domain-2=>3=>3=>2

新穎度: 45.0%

最大相似度: 55.0% (近似於: “The Application and Development of Artificial Intelligence in Taiwan’s News Communication”)

群集: 6

競賽得分: 3 勝

方法論契合度: 3/5

Methodology Reasoning: Extends target’s model with political moderation and survey experiment, but introduces new experimental design and content analysis not central to target’s mixed-methods approach.

問題陳述

在台灣，假新聞與錯誤資訊的傳播已對民主治理與公共健康造成嚴重威脅。事實查核被視為主要的回應機制，但現有事實查核系統往往採用「一刀切」的方式，忽略使用者政治立場與議題類型所引發的認知偏誤。研究顯示，當糾正資訊與使用者既有政治信念衝突時，會產生「信念迴聲」(belief echoes) 效應，即糾正非但無法改變錯誤信念，反而可能強化原有立場。此外，非政治性議題（如食安、醫療）的錯誤資訊糾正效果可能與政治性議題（如選舉、兩岸關係）截然不同。台灣社會高度兩極化，主要政治陣營（泛藍、泛綠）各自信任不同的資訊來源，因此缺乏政治適應性的事實查核系統可能效果不彰，甚至激化對立。本問題的關鍵在於：如何設計一個能夠辨識議題政治性、並根據使用者意識形態動態調整糾正策略的 AI 系統，以最大化糾正效果並最小化反彈？這不僅是技術挑戰，更涉及對政治心理學與傳播理論的深度整合。現有方法未能解決此問題，導致事實查核在特定群體中的影響力有限。

現有方法

現有事實查核系統主要分為兩類：(1) 人工為主的查核平台（如台灣事實查核中心、MyGoPen），依賴專家判斷與標準化報告格式，但缺乏個人化與即時性。(2) AI 輔助偵測系統，如基於深度學習的假新聞分類模型（如 BERT、GNN），以及參考引導的提示調整方法。這些方法在技術層面取得進展，例如目標論文訓練的模型達到 90.53% 正確率，但它們的侷限在於：(a) 假設所有使用者對糾正資訊的反應一致，未考慮政治動機推理 (motivated reasoning) 的影響。(b) 糾正來源的選擇固定（如總是引用主流媒體或政府機構），但對於不信任這些來源的群體，效果適得其反。(c) 缺乏對議題類型的區分，將政治與非政治議題視為同質。例如，相關文獻探討了食安假消息的查核行為，但未將政治因素納入模型。這些方法無法適應台灣多黨派、高信任分歧的資訊生態，因此需要一個能動態校準來源與內容的框架。

研究動機

現有方法之所以不足，是因為它們基於一個錯誤假設：事實查核是純粹的資訊處理過程，忽略使用者對資訊來源的政治情感依附。在台灣，民眾對媒體與機構的信任高度分化——泛藍支持者傾向相信中天電視、聯合報，泛綠支持者則信任三立、自由時報。當 AI 查核系統僅引用單一「權威」來源（如中央社或政府機關），對於不信任該來源的使用者，糾正資訊可能被視為偏見宣傳，反而鞏固原有錯誤信念。本研究的靈感來自於「來源信譽」與「認知失調」理論：若糾正資訊引用的來源與使用者政治歸屬一致，則

能繞過防禦機制，促進信念更新。此外，非政治議題（如食品添加物安全性）較不觸發身份認同，因此糾正效果可能更直接。因此，我們提出「政治適應性事實查核系統」(Politically Adaptive Fact-Checking System, PAFS)，其核心是根據使用者的政治傾向與議題類型，動態選擇最受信任的來源來呈現查核結果。這種方法預期能：(a) 降低政治動機推理的干擾，(b) 提高糾正資訊的接受度，(c) 減少「信念迴聲」效應。與現有標準化查核相比，PAFS 更尊重使用者的既有信任網絡，從而實現更有效的說服。

提出方法

本提案的方法分為三個階段：系統設計、內容分析與實驗驗證。

****第一階段：系統設計概述**** PAFS 的核心是一個 AI 引擎，它接收一則可疑訊息，首先進行議題類型分類（政治 vs. 非政治），然後根據目標使用者的政治傾向（透過使用者模型推斷，例如其社群媒體發文或瀏覽紀錄），從預先建立的「來源信任資料庫」中挑選一個或多個被該使用者群體高度信任的來源，並生成查核報告。報告的結構包括：錯誤主張、正確事實、以及引用來源。來源可以是媒體機構、專家個人、或政府單位，但需確保其對該使用者具有信譽。

****第二階段：內容分析**** 1. 資料收集：爬取台灣事實查核中心過去三年（2021-2024）的所有查核報告，約 1000 篇。2. 編碼：由兩名編碼員獨立對每篇報告進行：(a) 議題類型編碼：政治（選舉、兩岸、政黨、政策爭議）vs. 非政治（食安、醫療、環境、科技）；(b) 引用來源類型：媒體、政府、學術機構、民間組織；(c) 糾正語氣：中立、強硬、委婉。3. 建立來源信任資料庫：透過先導問卷調查（n=200），測量台灣民眾對主要媒體與機構的信任度，按政治傾向（泛藍、泛綠、中立）分組，建立各組信任度排名。

****第三階段：實驗驗證方法**** 採用 2（議題類型：政治 vs 非政治）× 3（使用者政治傾向：泛藍、泛綠、中立）× 2（查核來源類型：中立標準化 vs. 政治適應性）的混合因子設計。其中，議題類型與查核來源為受試者間因子，使用者政治傾向為測量變項。

****關鍵步驟：**** 1. 生成刺激材料：從內容分析中選取 6 則真實查核案例（3 政治、3 非政治）。對於每則案例，製作兩個版本的查核摘要：(a) 中立版本：引用台灣事實查核中心原報告的標準來源（如中央社）。(b) 政治適應版本：根據使用者傾向，動態調整引用來源。例如，對泛藍使用者引用中天電視或國民黨籍專家，對泛綠使用者引用三立電視或民進黨籍專家。對中立使用者則使用中立來源（如公視、學術期刊）。2. 問卷設計：包含前測（測量對原始錯誤訊息的信念強度，7 點李克特量表）、查核刺激呈現、後測（信念改變、對查核的信任度、分享意圖）。另加入操弄檢核題項（詢問使用者是否注意到引用來源）。3. 樣本招募：透過線上調查平台（如 SurveyMonkey）招募 500 名台灣公民，並透過篩選題確保政治傾向分布均勻（約各 1/3）。4. 分析策略：使用重複測量 ANOVA 檢驗信念改變，並以結構方程模型（SEM）檢驗信任度與分享意圖的路徑關係。主要假設為：政治適應性查核在政治議題上對極化使用者（泛藍/泛綠）的效果顯著優於中立查核，而在非政治議題上兩者差異較小。

此方法與現有工作最大不同在於：將來源選擇視為一種可操弄的設計參數，而非固定特質，並結合內容分析與實驗，確保外部效度。

實驗計畫

****步驟 1：建立來源信任資料庫**** - 進行前導問卷（n=200），透過社群媒體與 PTT 台灣看板招募，測量對 20 個主要台灣媒體與 10 個政府/學術機構的信任度（1-7 分）。- 將受訪者依政治傾向（投票行為與政黨認同題項）分為泛藍、泛綠、中立三組，計算每組對各來源的平均信任度，建立排名矩陣。

****步驟 2：刺激材料製作**** - 從台灣事實查核中心選取 6 則案例：3 則政治（如「某候選人學歷造假」、「中國介選」）、3 則非政治（如「萊豬致癌」、「疫苗副作用」）。每則案例製作兩個版本：- 中立版本：引用查核中心原始報告中使用的來源（通常是中央社或政府官員）。- 政治適應版本：根據來源信任資料庫，為每組使用者替換為該組信任度最高的來源。例如，對泛藍組引用中天新聞報導，對泛綠組引用三立新聞，中立組維持原來源或採公視。- 所有版本的字數與格式保持一致（約 150 字），僅引用來源名稱不同。

****步驟 3：正式實驗**** - 平台：Qualtrics。- 招募：委託專業市調公司（如 Pollster），確保樣本性別、年齡、教育程度分布符合台灣母體，並確保政治傾向比例（約 33% 泛藍、33% 泛綠、33% 中立）。總

樣本數 500 人。- 流程：1. 知情同意與人口統計。2. 政治傾向測量（政黨認同、2024 年投票意向）。3. 隨機分配至 6 種實驗情境（2 議題類型 × 2 查核來源版本 × 1 控制組無查核），每種情境約 80 人。4. 前測：呈現原始錯誤訊息，測量對該訊息的初始信念（1-7 分）。5. 刺激：呈現對應版本的查核摘要。6. 後測：信念改變（再次測量信念）、對查核的信任度（「你認為這個查核的可信度如何？」）、分享意圖（「你會願意在社交媒體上分享這個查核結果嗎？」）。7. 操弄檢核：詢問「你注意到查核報告中引用了哪些來源？」。

****步驟 4：分析**** - 使用 SPSS 或 R 進行重複測量 ANOVA，自變項為議題類型與查核來源版本，依變項為信念改變分數（後測信念 - 前測信念）。- 比較政治適應版本與中立版本在不同議題類型下的效果差異，特別針對極化使用者（泛藍/泛綠）。- 使用 SEM 檢驗信任度作為中介變項：查核來源 → 信任度 → 信念改變。- 成功指標：政治適應版本在政治議題上對極化使用者的信念改變顯著大於中立版本（ $p < 0.05$ ），且分享意圖更高。非政治議題上兩版本差異不顯著。

****步驟 5：系統原型開發**** - 基於實驗結果，設計一個簡單的 Web 應用程式原型，輸入使用者政治傾向（透過簡短問卷），並根據議題類型推薦最適來源。- 評估：邀請 20 位受試者試用，進行質性訪談了解接受度。

****資料集與評估指標**** - 資料集：台灣事實查核中心公開資料（提供案例）。- 基線：中立標準化查核版本。- 指標：信念改變量（主要）、信任度評分（次要）、分享意圖（次要）。

可信新穎度 — 最接近的真實論文

- The Application and Development of Artificial Intelligence in Taiwan's News Communication (55.0% · airiti.AL, 2021) — 區隔明確：該論文聚焦於 AI 在新聞傳播中的應用與信任問題，並訓練假新聞辨識模型（正確率 90.53%），但未探討使用者政治傾向與議題類型對糾正效果的調節作用。本提案則設計政治適應性的事實查核系統，透過實驗操弄查核來源的動態調整，直接測試不同意識形態群體對 AI 生成糾正資訊的反應差異，這是該論文完全未觸及的研究角度與方法。
- Empirical Research on Fake News Detection Using AI Technology (53.5% · airiti.AL, 2021) — 區隔明確：該論文同樣運用 AI 與 NLP 技術開發新聞可信度評估系統，但重點在於模型辨識率的提升與技術可解釋性問題，未考慮使用者政治偏誤或議題政治性對糾正效果的影響。本提案則從政治心理學與傳播理論出發，透過實驗設計比較中立與政治適應性查核來源的效果，並納入使用者意識形態作為調節變項，研究問題與方法截然不同。
- Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan's Newsrooms (51.9% · airiti.AL, 2025) — 區隔明確：該論文探討生成式 AI 在台灣新聞室的採用動機（創新與經濟因素），屬於新聞產製端的質化研究。本提案則聚焦於事實查核系統的設計與效果驗證，採用量化實驗方法，關注使用者端的認知偏誤與糾正策略，兩者在研究問題、方法與對象上均無直接重疊。

參考文獻

1. A comprehensive review of fake news detection on social media: feature engineering, feature fusion, and future research directions
2. Fake News Detection: A Graph Neural Network Approach
3. Reference-Guided and Domain-Invariant Late Prompts for Fake News Early Detection
4. Exploring the persuasive strategies and game design elements and possible demographic differences for energy saving behavior support system design
5. Exploring Fact-Checking Behavior: A Case Study on Food Safety Message

6. Factors and their effects of precautionary measures and fact-checking behavior toward food-safety misinformation
7. Taiwanese Media reporting COVID-19 disinformation crisis: A mixed-method study of technological epidemic prevention regarding health personal data, privacy and security issues
8. Influencing Factors and Their Effects on Precautions for Food Safety Misinformation: Based on the Theory of Planned Behavior
9. Content Characteristics and Verification Strategies of Fake News about COVID-19— A Case Study of the Taiwan Fact-Check Center
10. Prevention of fakes news can learn from the COVID-19's control experience in Taiwan
11. Non-Political Issue, Political Issue and Fact-Checking : An Examination of the Effectiveness of Fact-Checking in Taiwan
12. A Communicative Ecology Study of Users' Sharing of Misinformation Correction
13. Exploring the Effects of Game-Based Learning Through the Metaverse on Audience Awareness, Verification Behavior, and Intrinsic Motivation: A Case Study on the Issue of Fake News
14. Exploring Why People Do Not Report Fake News from the Perspective of Perceived Value and Perceived Risk
15. Exploring the Effects of Game-Based Learning through the Metaverse and Tabletop Games on Audience Awareness, Verification Behavior, and Intrinsic Motivation: A Case Study on the Issue of Fake News
16. Belief Echoes: The Impact of Fake News and Fact-checking News on Affection of Brand
17. Comparative Study of Machine Learning Approaches for Detecting Fake News in Arabic Text
18. Explore the Style for Fake News Detection
19. Toward Automatic Misinformation Detection Utilizing Fact-checked Information
20. Hyperpartisan News Classification with ELMo and Bias Feature
21. Claim Detection in Tweets
22. Exploring the Linguistic Style Disparities between AI-generated and Manually Written Fact-check Reports: A Case Study on COVID-19 Fake News
23. The Application and Development of Artificial Intelligence in Taiwan's News Communication
24. Copyright Strategy for AI Generated News from the Perspective of Incentive Theory
25. The Strength and Limitation of AI Embedding News: The Competition for the Professional Power of Journalism between ChatGPT and Journalists from the Perspective of Human-Machine Relationship
26. The Impact of Explainability on Users with Divergent Attitudes in AI-Supported Decision-Making Tasks

27. Effects of Algorithm Aversion and Betrayal Aversion on Trust in AI
28. Historical Changes and Contexts in the Routine of Copy editors in Postwar Japan's Newsrooms: Through the Magazines Published by Nihon Shinbun Kyokai
29. A Study to Investigate Professional Sources and Content Presentations Affecting News Credibility
30. Research on the Credibility of Content Broadcasted by AI and Human Anchors
31. AI, Newsroom Automation, and the Configuration of News in Transformation
32. Trust relationship between audiences and media: "Joui-wei rice event" for a case study
33. Report on the APAC Trusted Media Summit 2023
34. Gendering chatbots by design and its impacts on users trust towards shopping chatbots
35. News Consumption in the Changing Media Landscape 2024 Part I
36. The Wage Levels of Taiwanese Journalists under the Transformation of Technology: The Status Quo and Possible Solutions from a Critical Political Economy Perspective
37. Exploring Advertorials in Television News: Product Placement vs. Professionalism of News Reporting
38. Warrior of Journalism: Further Discussion of Current Journalism Education in Taiwan
39. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
40. 人工智能在美國新聞業的應用與影響
41. 從"人機協同"看人工智慧時代的新聞倫理建構
42. 媒體可信度研究：起源，發展，機會和挑戰
43. 人工智能對新聞業影響的對策分析
44. 汪志堅 | AI 深度學習與假新聞偵測
45. 數據新聞：大數據時代新聞可視化傳播的創新路徑
46. 大數據與新聞報導
47. 大數據方法與新聞傳播創新：從理論定義到操作路線
48. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
49. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
50. 再論後真相：基於時間與速度的視角
51. Post-truth，後真相的真相
52. 誰帶風向：被金錢操弄的公共輿論戰爭
53. 不是臺灣獨有- 大選假新聞成全球流行病

可解釋人工智慧輔助假新聞辨識對台灣民眾媒體信任與資訊分享行為之影響：一項隨機對照實驗

後設資料

想法編號: seed-domain-5=>3=>2=>1

新穎度: 25.1%

最大相似度: 74.9% (近似於: “The Application and Development of Artificial Intelligence in Taiwan’s News Communication”)

群集: 9

競賽得分: 3 勝

方法論契合度: 5/5

Methodology Reasoning: Directly extends the target’s AI fake news detection model by integrating explainable AI (XAI) and conducts a randomized controlled experiment measuring media trust and sharing behavior, closely matching the target’s mixed-methods design and focus on AI adoption and trust.

問題陳述

在台灣，假新聞的泛濫已嚴重侵蝕民眾對媒體的信任，並導致社會資訊環境惡化。目標論文指出，AI 假新聞辨識模型雖可達到 90.53% 的正確率，但現有模型多為「黑盒」，使用者無法理解其決策邏輯，可能導致對 AI 辨識結果的疑慮、拒絕使用，甚至反向強化對不實資訊的信念。同時，媒體信任的崩壞不僅來自假新聞本身，也來自民眾對資訊審查機制的不信任。可解釋 AI (XAI) 透過提供決策理由（如特徵熱圖或文字解釋），有潛力增進使用者對 AI 系統的信賴，並可能影響其對媒體的整體態度。然而，目前缺乏實證研究探討在台灣社會文化脈絡下，可解釋 AI 如何調節使用者對假新聞辨識結果的接受度、對媒體的信任度，以及後續的資訊分享意願。本計畫旨在填補此研究缺口，透過隨機對照實驗，系統性比較黑盒模型與可解釋模型對上述變項的因果效應，並探討可解釋性作為媒體信任重建干預手段的可行性。此問題的重要性在於：若能證實可解釋 AI 能提升使用者的媒體信任並降低假新聞分享，將為台灣事實查核機構、社群媒體平台與政府單位提供具體的技術與政策建議。

現有方法

現有方法主要分為三大類。第一類是純技術導向的假新聞辨識模型，如目標論文提出的深度學習模型，以及 XFlag 等可解釋模型 (LRP、SAT)。這些模型在準確率上表現優異，但其研究焦點在於技術效能，而非使用者心理與行為影響。第二類是媒體素養介入研究，例如事實查核課程（如針對樂齡長輩的課程）或媒體素養量表開發，這些方法強調教育與認知提升，但缺乏對 AI 輔助系統的直接比較，也無法釐清可解釋性本身的效果。第三類是行為實驗，如準確性提示實驗 (Accuracy Prompt)，探討簡單提示對分享判斷的影響，但該類研究未涉及 AI 輔助決策，亦未測量媒體信任的長期變化。此外，現有事實查核報告（如台灣事實查核中心）常缺乏系統性可解釋性，且多為事後補救，而非即時輔助。基於上述分析，現有方法的主要限制包括：(1) 未將可解釋 AI 視為一種心理干預手段；(2) 缺少對媒體信任與分享行為的同時測量；(3) 實驗多為橫斷面或未控制模型類型變項。因此，現有方法不足以回答「可解釋性如何改變使用者對媒體與 AI 的雙重信任」此一關鍵問題。

研究動機

現有方法之所以不足，是因為它們假設「高準確率=高接受度」，忽略了使用者對 AI 系統的認知負擔與信任門檻。在假新聞辨識的情境中，使用者若無法理解 AI 為何將某則新聞標記為假，可能產生抗拒 (reactance) 或懷疑偏誤 (skepticism bias)，導致即使模型正確，使用者仍不願接受結果。可解釋 AI 的引入，透過提供透明化的決策路徑 (例如，指出哪些詞彙或句子導致假新聞判定)，可能降低使用者的不確定感，並轉化為對 AI 系統的「程序信任」(procedural trust)。此外，媒體信任的建立往往依賴於資訊來源的可靠性；當 AI 系統能清楚展示其判斷依據時，使用者可能將此透明度類推至對媒體整體的信任，形成信任轉移效應。本研究動機來自於社會心理學的「透明度效應」(transparency effect) 與人機互動的「可解釋性信任模型」(explainability-trust model)。我們推論：相較於黑盒模型，可解釋模型能：(1) 提升使用者對 AI 辨識結果的信賴度；(2) 正向調節使用者對媒體的信任 (尤其是對新聞內容的信任)；(3) 降低使用者對不實新聞標題的分享意願。此方法之所以能優於現有基線，是因為它直接回應使用者的認知需求，而非僅依賴模型效能。此外，本計畫整合了技術開發與行為科學實驗，具有跨領域創新性，預期成果能為台灣的媒體信任重建提供實證基礎。

提出方法

本計畫提出一個兩階段的混合研究方法。第一階段為可解釋 AI 系統開發，第二階段為隨機對照實驗。

第一階段：可解釋假新聞辨識工具開發。基於目標論文之 AI 模型 (以 BERT 為基礎，訓練於 CoFacts 真的假的資料集，正確率 90.53%)，整合 XFlag 的可解釋框架。具體步驟如下：1. 模型微調：使用台灣事實查核中心與 CoFacts 的繁體中文新聞語料 (約 5 萬則，含真實與假新聞標題)，微調預訓練的 BERT-base-chinese 模型。訓練損失函數為交叉熵，優化器為 Adam。2. 解釋生成：針對每則新聞標題，採用兩種可解釋技術：- LRP (層級相關性傳播)：計算每個詞彙對分類結果的貢獻分數，並以熱圖 (heatmap) 形式視覺化，詞彙顏色越紅表示貢獻越大。- SAT (自我注意力轉換)：提取模型最後一層的注意力權重，並以文字列表呈現「模型特別關注的關鍵詞」，例如「模型判斷此為假新聞，因為『緊急』、『獨家』、『未經證實』等詞彙的權重較高」。3. 工具介面設計：開發一個簡易網頁應用程式，隨機呈現新聞標題。每則標題下方顯示：- 黑盒版本：僅顯示「AI 辨識結果：真實新聞/假新聞」及信心分數 (0-100%)。- 可解釋版本：顯示相同結果與信心分數，外加 LRP 熱圖 (標題內詞彙著色) 與 SAT 文字解釋。

第二階段：隨機對照實驗。1. 參與者招募：透過網路廣告與學術社群招募 300 名台灣民眾 (18 歲以上，每天使用社群媒體至少 30 分鐘)。排除新聞傳播相關科系學生，以避免專業偏誤。2. 隨機分組：參與者以 1:1 比例隨機分派至黑盒組 (n=150) 或可解釋組 (n=150)。分層隨機化依據性別與年齡分層。3. 實驗流程：所有參與者透過線上平台 (如 Qualtrics 或 LimeSurvey) 進行，步驟如下：- 前測問卷：填寫人口統計變項、媒體信任量表 (採用台灣版媒體信任量表，Cronbach's $\alpha > 0.8$)、AI 態度量表 (改編自技術接受模型)。- 訓練階段：觀看 5 則範例新聞標題 (3 真 2 假)，熟悉工具操作。可解釋組觀看解釋版本，黑盒組觀看無解釋版本。- 正式實驗：隨機呈現 30 則新聞標題 (15 真、15 假，來自 CoFacts 與台灣事實查核中心，經專家驗證)，每則標題呈現後，參與者需完成：a. 對 AI 辨識結果的信賴度 (1-7 Likert 量表，1=非常不信賴，7=非常信賴)。b. 分享意願 (「如果您在社群媒體上看到此標題，您有多可能分享它？」1-7 Likert 量表)。- 後測問卷：再次測量媒體信任量表與 AI 態度量表，並加入系統可用性量表 (SUS) 與開放式問題 (例如：「您覺得 AI 的解釋對您有幫助嗎？」)。4. 數據分析：使用意向治療分析 (ITT)。主要分析為獨立樣本 t 檢定 (比較兩組在 AI 信賴度、分享意願、媒體信任後測的平均差異)；次分析為多層次迴歸 (控制前測媒體信任、年齡、教育程度)，檢驗可解釋性的調節效果；中介分析使用 Bootstrap 法 (PROCESS macro Model 4)，探討 AI 信賴度是否為可解釋性影響媒體信任的中介變項。

此方法的新穎性在於：(1) 首次在台灣以實驗法比較黑盒與可解釋 AI 對媒體信任的因果效應；(2) 同時測量 AI 信賴度與媒體信任，探討兩者動態關係；(3) 整合技術開發與行為科學，提供可複製的實驗範式。

實驗計畫

實驗步驟詳細如下：

第一步：準備實驗材料與系統。- 資料集：從 CoFacts 真的假的與台灣事實查核中心收集 2020-2024 年間的繁體中文新聞標題，共 100 則（50 真、50 假），由兩位獨立編碼員驗證真實性（Cohen's Kappa > 0.8）。從中選取 30 則（15 真、15 假）作為實驗刺激，剩餘 70 則用於模型訓練與驗證。確保新聞主題涵蓋政治、健康、生活、科技等領域，以提升生態效度。- 模型訓練：使用 70 則資料（每則含標題與標籤）微調 BERT-base-chinese，並以 5 折交叉驗證評估模型，確保準確率接近目標論文的 90.53%。若準確率低於 85%，則擴充資料集至 200 則。- 解釋生成：對 30 則實驗刺激，預先計算 LRP 熱圖與 SAT 解釋，儲存為 JSON 格式，以利網頁工具快速載入。- 網頁工具開發：使用 Python Flask 框架，前端以 HTML+CSS+JavaScript 呈現。隨機化功能由後端分配 URL 參數（group=blackbox 或 xai），確保參與者無法得知分組。

第二步：參與者招募與前測。- 透過 PTT、Dcard、Facebook 廣告招募，目標 300 人。篩選條件：年滿 18 歲、目前居住台灣、每日使用社群媒體至少 30 分鐘。排除條件：新聞傳播科系學生、曾參與類似研究。- 前測問卷內容：年齡、性別、教育程度、政治傾向、社群媒體使用頻率、媒體信任量表（12 題，如「我信任台灣主流媒體報導的新聞」）、AI 態度量表（6 題，如「我認為 AI 的判斷比人類可靠」）。所有量表採用 7 點李克特量表。

第三步：實驗干預。- 參與者點擊連結後，自動導向訓練階段。訓練階段結束後，進入正式實驗。每則新聞標題呈現時，計時器紀錄閱讀時間（秒）。可解釋組的標題下方顯示熱圖與文字解釋；黑盒組僅顯示結果與信心分數。每則標題後，立即彈出兩個問題（AI 信賴度、分享意願）。- 順序效應控制：30 則新聞以隨機順序呈現，但確保每種分組的順序相同（即使用相同的隨機種子）。

第四步：後測與數據清理。- 後測問卷包括媒體信任量表（與前測相同）、AI 態度量表、系統可用性量表（SUS，10 題）。另加注意力檢查題（例如：「請問本實驗中，AI 辨識模型的正確率大約是多少？」），排除未通過者。- 數據清理：剔除填答時間少於 5 分鐘、或所有題項選擇相同選項、或注意力檢查失敗的參與者。預計有效樣本至少 250 人。

第五步：統計分析。- 使用 SPSS 或 R 進行分析。主要變項：AI 信賴度（30 題平均）、分享意願（假新聞標題的平均分享意願，真新聞標題的平均分享意願）、媒體信任後測分數。- 主要假設檢驗：H1: 可解釋組的 AI 信賴度顯著高於黑盒組（獨立樣本 t 檢定）。H2: 可解釋組對假新聞標題的分享意願顯著低於黑盒組。H3: 可解釋組的媒體信任後測分數顯著高於黑盒組（控制前測分數後，ANCOVA）。- 中介分析：以可解釋性為自變項（0=黑盒，1=可解釋），媒體信任後測為依變項，AI 信賴度為中介變項，使用 PROCESS 的 Model 4，Bootstrap=5000 次，95% 信賴區間。- 成功標準：若 H1、H2、H3 均達統計顯著（ $p < 0.05$ ），且中介分析的信賴區間不包含 0，則證明可解釋 AI 能有效提升媒體信任並減少假新聞分享。此外，預期效果量（Cohen's d）至少達 0.3（中小效果）。

第六步：額外探索性分析。- 檢驗政治傾向是否調節效果：將參與者分為泛藍、泛綠、中立，進行多因子 ANOVA。- 檢驗閱讀時間與 AI 信賴度的相關性：若可解釋組閱讀時間越長，信賴度越高，表示解釋內容被認真處理。- 開放式問題的內容分析：歸納參與者對可解釋性的質性回饋，以補充量化結果。

可信新穎度 — 最接近的真實論文

- The Application and Development of Artificial Intelligence in Taiwan's News Communication (74.9% · airiti.AL, 2021) — 增量: 該論文主要探討 AI 在新聞傳播領域的應用與對媒體信任的侵蝕，並提出以 AI 模型（正確率 90.53%）作為解決方向，但未進行任何實驗或實證研究來驗證可解釋 AI 對使用者行為的因果效應。本提案則透過隨機對照實驗，直接比較黑盒模型與可解釋模型對媒體信任與資訊分享行為的影響，並以 XAI 技術（LRP 與 SAT）作為干預手段，這是該論文完全未觸及的方法與研究問題。（相似度 75% 偏高，標籤經相似度守衛下修）
- Empirical Research on Fake News Detection Using AI Technology (73.7% · airiti.AL, 2021) — 增量: 該論文同樣開發了假新聞辨識 AI 模型（正確率 90.53%），並提及可解釋性與人類自主性等問題，但僅停留在技術開發與概念討論層面，未進行任何使用者實驗或因果推論。本提案則

以該模型為基礎，進一步整合可解釋 AI 框架，並設計隨機對照實驗來系統性測量可解釋性對媒體信任與分享行為的因果效應，這是該論文缺乏的實證貢獻。(相似度 74% 偏高，標籤經相似度守衛下修)

- Exploring Artificial Intelligence Technologies for Fake News Detection (72.6% · airiti.AL, 2021) — 增量: 該論文聚焦於比較人類與電腦在中文假新聞偵測上的表現，並使用 Naïve Bayes、SVM 及 BERT 等模型進行預測，但未探討 AI 決策的可解釋性對使用者行為的影響，也未進行任何隨機對照實驗。本提案則以可解釋 AI 為核心，透過實驗設計檢驗 XAI 對媒體信任與資訊分享的調節效果，研究問題與方法與該論文有根本差異。(相似度 73% 偏高，標籤經相似度守衛下修)

參考文獻

1. XFlag: explainable fake news detection model on social media
2. Exploring Artificial Intelligence Technologies for Fake News Detection
3. Fake News Detection: A Graph Neural Network Approach
4. The effects of fact-check courses on fact-checking skills and misinformation detection in older adults
5. Development of A New Online Media Literacy Scale
6. A Preliminary Study on the Analytical Method of Systematic Fact Checking of Military Photographic Images - Using Pelosi Visit to Taiwan as an Example
7. Exploring the Impact of Accuracy Prompt on the Evaluation and Sharing Discernment of Social Media News Headlines
8. TV Journalists' Social Media Dependency in Disaster News Verification
9. Trust relationship between audiences and media: "Joui-wei rice event" for a case study
10. Media Credibility Research: Origin, Development, Opportunity, and Challenges
11. Study on perceptions of fake news and education for undergraduate students
12. Discussion on the Promotion of News Media Literacy and Evaluation to Prevent Fake News
13. The effectiveness and the subject of fact check in fake news measures
14. 應用自然語言處理技術於中文網路新聞立場識別
15. Detecting media bias in online news in Taiwan using natural language processing
16. The Role of Digital Information Accessibility in Shaping the Relationships of Exposure to COVID-19 Misinformation and Cognitive and Attitudinal Effects in Asia
17. A Communicative Ecology Study of Users' Sharing of Misinformation Correction
18. The EU Strategy and Regulation on Disinformation
19. Argument About the Regulation of Disinformation and the Boundary of Freedom of Speech-From U.S. Legal Practice Aspect

20. When Zombies Invade Taiwan - Current Status and Future Challenges of Facebook Fake Accounts and Disinformation
21. The Impact of Disinformation Classification on Voters' Candidate Evaluation with Different Politic Identity and Politic Knowledge
22. 從歐盟、澳洲經驗探討我國假訊息治理議題
23. The Liability for Misrepresentations of Sustainability Information: Focusing on Investor Protection
24. 歐盟打擊線上「非法仇恨言論」及「不實資訊」行為之治理模式
25. Hierarchical Operation Mechanisms and Governance of Disinformation in the Era of Generative AI
26. 媒體素養教育首應導正年輕世代的使用觀念
27. An Exploratory Study of Development and Usage of an Artificial Intelligence Identification System of News Source Credibility
28. Chinese Communist Party' s propaganda on Taiwan by social media:" Douyin of China"
29. Separate the Wheat from the Chaff: Taiwan's Challenges and Mitigation Strategies Against Disinformation
30. Exploring the Operation Modes of Disinformation on Social Media: Two Political Disinformation Cases in Taiwan
31. Tango Under the COVID-19 Infodemic: Taiwan's Practice of and Reflection on Fact-checking Journalism
32. The Application and Development of Artificial Intelligence in Taiwan's News Communication
33. Regulatory Models on Disinformation and its Legitimacy – A Perspective from International Declarations and Comparative Law
34. A Study of Disinformation in the Pro-Communist Media in Taiwan in the Information War
35. Whom Are News Bots " Laboring " for? Effects of Automated Journalism on Journalists
36. Understanding Important Language Features of Fake News: Word Patterns as Neural Networks Inputs
37. Exploring the Linguistic Style Disparities between AI-generated and Manually Written Fact-check Reports: A Case Study on COVID-19 Fake News
38. Report on the APAC Trusted Media Summit 2023
39. Validating the effectiveness of fact-check alerts
40. Media Literacy in an age of Artificial Intelligence: An exploratory research from HMC
41. Smart Web Generator based on Artificial Intelligence and Web Crawler Techniques

42. The Wandering Truth: Media Representation about " Human and Artificial Intelligence " and Its Discourse, Political and Economic Criticism
43. The Balancing Approach as a Way of Thinking about the Ethics of News Reporting
44. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
45. 人工智能在美國新聞業的應用與影響
46. 從”人機協同”看人工智慧時代的新聞倫理建構
47. 媒體可信度研究：起源，發展，機會和挑戰
48. 人工智能對新聞業影響的對策分析
49. 汪志堅 | AI 深度學習與假新聞偵測
50. 數據新聞：大數據時代新聞可視化傳播的創新路徑
51. 大數據與新聞報導
52. 大數據方法與新聞傳播創新：從理論定義到操作路線
53. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
54. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
55. 再論後真相：基於時間與速度的視角
56. Post-truth，後真相的真相
57. 誰帶風向：被金錢操弄的公共輿論戰爭
58. 不是臺灣獨有- 大選假新聞成全球流行病

「協作還是抵抗？」：生成式 AI 重構臺灣新聞室勞動過程與專業認同之研究——從認知勞動到邊界工作

後設資料

想法編號: seed-domain-4=>1=>1=>2

新穎度: 29.1%

最大相似度: 70.9% (近似於: “Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan’s Newsrooms”)

群集: 4

競賽得分: 2 勝

方法論契合度: 2/5

Methodology Reasoning: Employs interviews and surveys on labor and identity, diverging from target’s focus on fake news detection and model evaluation; lacks the experimental and accuracy analysis components.

問題陳述

隨著生成式 AI (如 ChatGPT、Jasper 等) 迅速滲入新聞產製流程，臺灣新聞從業者正面臨前所未有的勞動過程轉型。現有研究多從產業經濟學或技術接受模型出發，強調 AI 如何提升效率、降低成本，或從批判政治經濟學角度探討資本對勞動的宰制。然而，這些研究往往忽略了兩個關鍵問題：第一，生成式 AI 對記者「認知勞動」的具體影響——記者如何運用專業判斷來校準、修補或拒絕 AI 生成的敘事？AI 是否導致記者「去技能化」或「再技能化」？第二，記者如何透過「邊界工作」(boundary work) 來劃分人機之間的專業界線，從而維護自身在新聞場域中的權威地位？在臺灣獨特的媒體生態中——高度競爭的數位原生媒體與傳統主流媒體並存、假訊息氾濫、閱聽人信任度低落——這些問題更具現實意義。本研究試圖填補這些理論與實證缺口，透過勞動過程理論與技術社會學的對話，系統性地檢視生成式 AI 如何重塑臺灣記者的日常實作、專業認同與知識主體性。本研究不僅能為新聞教育與媒體政策提供實證依據，更能豐富我們對 AI 時代專業勞動之理解。

現有方法

現有研究主要分為三條路徑：第一，量化調查法（如技術接受模型 TAM）測量記者對 AI 的態度與採用意願，但忽略了工作脈絡與協商過程。第二，質化訪談法（如半結構訪談）探討 AI 導入的組織決策與經濟動機，例如《科技創新還是經濟動機？臺灣新聞室生成式人工智慧科技採用之初探》一文，但訪談對象多為編輯台主管，缺乏對一線記者日常實作的微觀觀察。第三，文本分析法用以比較人機生成內容的語意差異，但未連結到記者的主體性與專業認同。這些方法的共同限制在於：未將 AI 視為一個「行動者」，而是被動工具；忽略了記者與 AI 之間的動態互動（如校對、調整、拒絕）；以及未能捕捉記者如何透過敘事框架來協商專業邊界。例如，《人工智慧科技在臺灣新聞傳播領域之運用與發展》雖探討 AI 對媒體信任的侵蝕，但未深入勞動過程。《Whom Are News Bots “Laboring” for?》從政治經濟學批判出發，但缺乏對記者自身策略的細緻分析。因此，需要一個整合認知勞動、邊界工作與技術協商的創新方法。

研究動機

現有方法之所以不足，是因為它們傾向於將記者視為被動的技術接受者或結構壓力的受害者，而忽略了記者作為能動主體如何在日常實作中重新定義其專業角色。我的靈感來自於「認知勞動」理論——強

調知識工作者如何投入心智努力來詮釋、評估與修正資訊——以及「邊界工作」概念——專業群體如何劃分內外群體的界線以維護權威。在生成式 AI 時代，記者必須同時進行兩種勞動：一是與 AI 協作時對其輸出進行「再脈絡化」(re-contextualization) 的認知勞動，二是與組織管理層、讀者與其他專業群體協商 AI 角色定位的邊界工作。本研究所提出的「人機協作敘事框架」(Human-AI Collaborative Narrative Framework, HACNF) 將透過錄影民族誌與對話分析，捕捉記者與 AI 互動的微觀過程，並輔以語料庫輔助的文本分析，量化記者對 AI 文本的修改程度與策略。這種方法能更精確地揭示 AI 是「賦能」還是「剝奪」記者的專業技能。相較於基準方法，HACNF 能同時捕捉結構限制與能動性，並提供可操作的干預建議（如新聞教育課程設計）。

提出方法

方法概述本研究所提出的「人機協作敘事框架」(HACNF) 整合了三層分析：微觀工作流（記者與 AI 的即時互動）、中觀組織協商（編輯台內的角色協商）、宏觀制度環境（產業規範與閱聽人期待）。資料收集包括：(1) 工作錄影與對話分析；(2) 深度訪談；(3) 修改文本的語料庫分析；(4) 控制實驗。

詳細步驟#### 步驟一：場域選取與參與者招募選取臺灣六家新聞組織——兩家傳統主流媒體（如《聯合報》、《中國時報》）、兩家數位原生媒體（如《報導者》、《關鍵評論網》）、兩家電視媒體（如《TVBS》、《公視》）。每家組織招募 3-5 名記者與 1-2 名編輯主管，共 30-40 名參與者。確保樣本涵蓋不同資歷、性別與政治立場。

步驟二：工作錄影與對話分析（微觀層）在參與者的工作電腦上安裝螢幕錄影軟體（經知情同意），連續錄製兩週的工作過程（每日 4 小時）。錄影同時，使用手機或外接麥克風錄製環境音與口語對話。研究者每天進行一次簡短回顧訪談（10-15 分鐘），詢問錄影片段中的關鍵決策點。

隨後，研究者使用對話分析（Conversation Analysis）編碼記者與 AI 的互動序列。編碼類別包括：-「直接接受」：記者未修改即使用 AI 輸出。-「修補」：記者調整語氣、事實或結構。-「駁回」：記者決定不用 AI 輸出。-「質詢」：記者對 AI 輸出提出疑問（如「這數據哪來的？」）。-「擴展」：記者基於 AI 輸出進行深入採訪。

編碼將由兩位研究者獨立進行，Cohen's Kappa > 0.8。

步驟三：深度訪談（中觀層）在錄影結束後，對每位參與者進行一小時的半結構訪談。問題範例：-「請描述一個你最近使用 AI 輔助寫稿的具體案例。你做了哪些調整？」-「你認為使用 AI 後，你的專業技能（如判斷力、採訪能力）是提升還是下降？」-「你的主管對 AI 使用有何期待？你是否感到壓力？」-「你如何向讀者解釋 AI 在報導中的角色？」

訪談將被轉錄並進行主題分析（Thematic Analysis），編碼類別包括：專業認同、技能變遷、組織權力、倫理焦慮。

步驟四：修改文本的語料庫分析（宏觀層）收集記者使用 AI 前後的文本版本。使用 Python 的語料庫工具（如 spaCy、NLTK）比較：- 詞彙複雜度（Type-Token Ratio）- 句式長度- 情感極性（使用 NTUSD 情感詞典）- 客觀性分數（透過 SentiWordNet）- 事實性錯誤率（由兩位研究助理人工校驗）

同時，計算「修改程度指數」(Modification Intensity Index, MII)，定義為記者修改字數佔原始 AI 輸出的比例。MII > 0.5 表示高介入，MII < 0.2 表示低介入。

步驟五：控制實驗設計一個 2×2 情境實驗，自變項為「任務類型」（事實性報導 vs. 評論性報導）與「AI 使用狀態」（強制使用 vs. 自由選擇）。招募 60 名新聞系學生與在職記者作為受試者。依變項為：報導品質（由三位資深編輯盲評）、完成時間、自我報告的專業成就感。實驗結果將與錄影數據進行三角驗證。

實驗計畫

實驗階段與執行步驟

第一階段：場域準備與倫理審查（第 1-2 個月）- 向臺灣六家新聞組織提交研究計畫書，取得合作同意。- 申請人體研究倫理審查（IRB），確保所有參與者簽署知情同意書，並保護數據隱私。-

招募 30-40 名記者與編輯，發放研究參與補助金（每人新台幣 5,000 元）。

第二階段：工作錄影與回顧訪談（第 3-4 個月）- 安裝錄影軟體（如 OBS Studio），設定錄影片段為每段 30 分鐘，自動儲存至加密雲端。- 每天結束後，研究者觀看錄影並標記關鍵事件（如記者與 AI 互動的片段）。- 每週進行一次群體回顧座談（每人 30 分鐘），討論共同經驗。

第三階段：深度訪談（第 5 個月）- 安排一小時一對一訪談，透過 Zoom 或面對面進行。- 使用 NVivo 軟體進行主題分析，編碼一致性由兩位研究者交叉校驗。

第四階段：文本語料庫分析（第 6-7 個月）- 收集記者提供的原始 AI 輸出與最終發表版本（約 200 篇報導）。- 使用 Python 進行語料庫分析，計算 MII、情感極性等。- 人工校驗事實錯誤（每篇報導由兩位助理獨立比對原始來源）。

第五階段：控制實驗（第 8-9 個月）- 透過學術社群（如臺灣媒體觀察教育基金會）招募 60 名受試者（30 名在職記者、30 名新聞系大四學生）。- 實驗在靜態實驗室進行，使用標準化 AI 工具（統一使用 GPT-4 API）。- 任務 A：「撰寫一則關於松山機場擴建案的事實報導」（提供 5 份公文與訪談摘要）。- 任務 B：「撰寫一篇關於 AI 倫理的評論」（提供 3 篇學術論文摘要）。- 每位受試者分別在「強制使用 AI」與「自由選擇」條件下完成任務（隨機順序）。- 評分：三位資深編輯（不知實驗條件）使用 1-7 分量表評報導的準確性、深度、可讀性與原創性。

第六階段：數據分析與論文撰寫（第 10-12 個月）- 量化數據：使用多層次線性模型（HLM）分析錄影編碼、MII 與訪談主題的關聯。- 控制實驗：使用重複測量 ANOVA 比較不同條件下的差異。- 質化數據：撰寫厚描述，呈現記者如何協商專業邊界。- 預期成功指標：若研究發現記者普遍進行高介入修改（MII > 0.5）、且訪談中多數人強調「AI 是工具而非取代者」，則支持「再技能化」假說；反之，若 MII < 0.2 且記者感到專業自主性下降，則支持「去技能化」假說。

第七階段：回饋與驗證（第 13 個月）- 將初步發現回饋給參與組織，舉辦一場工作坊討論結果。- 根據回饋修正分析，投稿至《新聞學研究》或《中華傳播學刊》。

可信新穎度 — 最接近的真實論文

- Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan's Newsrooms (70.9% · airiti.AL, 2025) — 增量：該論文僅以半結構訪談探討臺灣新聞室採用生成式 AI 的動機（創新 vs. 經濟），未深入分析記者與 AI 互動的微觀勞動過程，也未使用工作錄影、對話分析或控制實驗等方法。本提案聚焦於認知勞動與邊界工作，透過多層次方法（工作錄影、對話分析、語料庫分析、控制實驗）系統性地檢視記者如何修補、駁回或擴展 AI 輸出，以及如何維護專業界線，這是該論文完全未觸及的理論與實證缺口。（相似度 71% 偏高，標籤經相似度守衛下修）
- Whom Are News Bots "Laboring" for? Effects of Automated Journalism on Journalists (70.2% · airiti.AL, 2020) — 增量：該論文從批判政治經濟學視角進行論述分析，探討自動化新聞學如何影響勞動過程與專業意識形態，但未使用實證方法（如工作錄影、深度訪談、控制實驗）來觀察記者與 AI 的即時互動。本提案不僅聚焦於生成式 AI（而非一般自動化新聞學），更透過微觀工作流分析與邊界工作理論，具體記錄記者如何進行認知勞動（如修補、質詢 AI 輸出），並在臺灣媒體生態中進行實證研究，這是該論文缺乏的。（相似度 70% 偏高，標籤經相似度守衛下修）
- AI, Newsroom Automation, and the Configuration of News in Transformation (68.1% · airiti.AL, 2024) — 增量：該論文為概念性探討，描述生成式 AI 對新聞產製流程、組織型態與新聞樣貌的潛在影響，未進行系統性實證研究。本提案則提出具體的「人機協作敘事框架」，並透過工作錄影、對話分析、深度訪談、語料庫分析與控制實驗等多元方法，實證檢視記者如何與 AI 協作、協商專業界線，以及認知勞動的變化。該論文缺乏對記者日常實作與專業認同的微觀分析，而這正是本提案的核心。（相似度 68% 偏高，標籤經相似度守衛下修）

參考文獻

1. AI, Newsroom Automation, and the Configuration of News in Transformation
2. Whom Are News Bots " Laboring " for? Effects of Automated Journalism on Journalists
3. Gender Politics in a Non-Mainstream Newsroom: A Case Study of the Shih-Hsin University Publication Newsweek
4. The Practical Orientation for Materializing the Independent Knowledge System of Contemporary Chinese Journalism
5. The Strength and Limitation of AI Embedding News: The Competition for the Professional Power of Journalism between ChatGPT and Journalists from the Perspective of Human-Machine Relationship
6. 2A1-L02 Journalist Robot : Robot System Making News Articles from Real World
7. Generative Artificial Intelligence in News Media: Perceived Risks, Norms, and Practices
8. Tango Under the COVID-19 Infodemic: Taiwan's Practice of and Reflection on Fact-checking Journalism
9. The Application and Development of Artificial Intelligence in Taiwan's News Communication
10. Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan's Newsrooms
11. Consideration of ways to report sport culture
12. Enhancing healthcare efficiency with artificial intelligence: Benefits, challenges, and the future of clinical practice
13. Application of AI in Atmospheric Science
14. Artificial Intelligence, media, and constitutionalism
15. 報道は AI とどう向き合うのか
16. 新聞攝影倫理：悲慘報導中真實性與倫理道德問題的平衡
17. A Philosophical Analysis of AI - generated Works and the Copyright Law of China
18. Opportunities, Challenges and Countermeasures of News Communication in the Era of Artificial Intelligence
19. Guest editorial: Application and research of generative AI in education
20. Ethical Gaps in Journalism Education: How Journalism Students Perceive Journalistic Ethics and Media Performance
21. Taming v.s. Resistance: The Resistance Strategies of Media Professionalism for Chinese Government Political Power
22. Research on the Credibility of Content Broadcasted by AI and Human Anchors

23. A Review of Studies on the Political Effects of Social Media and AI Technologies: Reflecting on the Third Wave of SSS and Code/Space Theory
24. Humanistic News production in the Era of Intelligent Communication: Practical Situation and Theoretical Orientation
25. Implementation and Evaluation of an Interpretable Fake News Detector
26. Exploring Artificial Intelligence Technologies for Fake News Detection
27. Empirical Research on Fake News Detection Using AI Technology
28. Copyright Strategy for AI Generated News from the Perspective of Incentive Theory
29. 利用自然語言處理進行自動新聞分類之研究
30. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
31. 人工智能在美國新聞業的應用與影響
32. 從”人機協同”看人工智慧時代的新聞倫理建構
33. 媒體可信度研究：起源，發展，機會和挑戰
34. 人工智能對新聞業影響的對策分析
35. 汪志堅 | AI 深度學習與假新聞偵測
36. 數據新聞：大數據時代新聞可視化傳播的創新路徑
37. 大數據與新聞報導
38. 大數據方法與新聞傳播創新：從理論定義到操作路線
39. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
40. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
41. 再論後真相：基於時間與速度的視角
42. Post-truth，後真相的真相
43. 誰帶風向：被金錢操弄的公共輿論戰爭
44. 不是臺灣獨有- 大選假新聞成全球流行病

規範機器：生成式人工智慧倫理指南在台灣新聞室的制度化與在地調適

後設資料

想法編號: seed-domain-4=>1=>1=>1

新穎度: 31.9%

最大相似度: 68.1% (近似於: “Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan’s Newsrooms”)

群集: 8

競賽得分: 2 勝

方法論契合度: 3/5

Methodology Reasoning: Uses qualitative content analysis and interviews, partially matching target’s literature and case analysis, but focuses on norm diffusion and governance rather than AI detection experiments or media trust analysis.

問題陳述

生成式人工智慧 (GenAI) 的快速發展正在根本性地重塑新聞生產流程，從自動化內容生成到輔助編輯決策，其影響既深且廣。然而，這項技術在帶來效率提升的同時，也引發了深刻的倫理問題，包括事實性錯誤 (幻覺)、偏見複製、著作權爭議以及對新聞專業自主性的侵蝕。台灣新聞媒體在面臨經濟壓力 (如廣告收入下滑、讀者流失) 和 24 小時新聞循環的競爭下，已開始嘗試將 GenAI 整合到日常運作中，但對於如何規範其使用仍處於混沌狀態。現有的規範多為全球北方的跨國科技公司或國際新聞組織 (如 Reuters Institute) 所主導的通用倫理原則，這些原則往往將 AI 倫理簡化為技術性問題 (如準確性、透明度)，卻忽略了新聞室內部的權力動態、在地政治經濟脈絡、以及編輯室文化如何形塑規範的實際運作。更關鍵的是，既有研究多聚焦於規範的「內容」或「宣稱」，而非規範如何被「制度化」——即從書面政策轉化為日常實踐的動態過程。因此，本研究的核心問題是：在台灣新聞室中，生成式 AI 倫理指南是如何被採用、調適、甚至被忽視或抵抗的？全球規範如何在本地脈絡中被翻譯、重新詮釋或改造？這些制度化過程又如何反過來影響新聞專業自主性與公眾信任？這個問題之所以重要，是因為它不僅關乎新聞業的未來，更觸及科技治理、專業權力與民主社會資訊生態的核心。

現有方法

現有研究主要分為兩大類：一類是規範性研究，透過文獻分析或比較法，提出理想的 AI 倫理原則 (如歐盟 AI 法案、IEEE 的倫理指南)，這類方法常忽略實際執行面的困難與在地差異。另一類是實證研究，如問卷調查或內容分析，探討新聞從業者對 AI 的態度或政策文件的表面特徵。例如，相關文獻中〈Generative Artificial Intelligence in News Media: Perceived Risks, Norms, and Practices〉一作採用量化調查，發現新聞媒體對 GenAI 風險的認知與規範的推出之間存在落差，但未能深入解釋為何會有此落差。又如〈Technological Innovation or Economic Motivation?〉採用質化訪談，初步描繪了台灣新聞室採用 GenAI 的經濟動機，但未系統性地分析倫理規範的建立過程。這些方法的限制在於：(1) 靜態分析：多將規範視為固定文本，而非動態的社會建構；(2) 忽略權力：未充分考慮新聞室內部的階層關係 (如編輯部與管理層的張力)、性別政治 (如相關文獻中的〈Gender Politics〉顯示性別如何影響實務) 以及外部壓力 (如廣告主、科技平台) 對規範形成的影響；(3) 缺乏比較：未比較不同類型新聞室 (如主流媒體 vs. 獨立媒體) 的差異性制度化路徑。因此，既有方法不足以捕捉規範從「口頭承諾」到「日常慣例」的複雜轉化。

研究動機

現有方法之所以不足，是因為它們將 AI 倫理規範視為一個技術或法律問題，而非一個深嵌於社會文化與組織政治中的「規範創業」(norm entrepreneurship) 過程。我提出的方法受到社會學中的制度理論(如 DiMaggio & Powell 的同構化)及科技與社會研究(STS)的啟發，主張規範不是被動地被「採用」，而是被主動地「做」(enacted)。台灣的獨特脈絡——高度競爭的媒體市場、強烈的政黨傾向、以及對「假新聞」的社會焦慮——提供了一個絕佳的實驗場，來觀察全球規範如何被在地轉化。我的方法將結合深度訪談、參與式觀察與政策文本的批判論述分析，特別聚焦於「規範企業家」(即推動規範的關鍵人物，如倫理委員會主席或科技編輯)的能動性及其策略。相比於量化調查只能捕捉態度，質化方法能揭露規範背後的妥協、矛盾與權力協商。此外，我將引入一個大膽的比較維度：主流商業媒體(如《聯合報》、《自由時報》)與非營利獨立媒體(如《報導者》、《沃草》)的規範發展路徑有何不同？這能揭示經濟模式與組織文化如何影響規範的嚴謹性與執行力。我相信，這種「從下而上」的視角能產出比現有研究更細膩的洞見，並為新聞業提供具建設性的規範實務建議。

提出方法

本方法將採用「多重個案比較研究」設計，融合三種資料收集與分析技術：深度訪談、批判論述分析(CDA)、以及組織民族誌的參與式觀察。以下是詳細步驟：

****一、研究對象選取**** 選取 6 家具有代表性的台灣新聞媒體，分為三組：- 組 A (主流商業媒體)：2 家，分別代表偏藍與偏綠的報紙集團(如《聯合報》、《自由時報》)，因其擁有明確的 AI 政策文件。- 組 B (獨立非營利媒體)：2 家(如《報導者》、《端傳媒》)，因其以公眾信任為核心，可能發展出更嚴謹的規範。- 組 C (新創數位媒體)：2 家(如《關鍵評論網》、《INSIDE》)，因其高度依賴科技，且規範可能較為鬆散。每家媒體將選取 2-3 名關鍵受訪者：總編輯、科技線編輯、以及倫理委員會成員(若存在)。

****二、資料收集**** 1. ****政策文本收集**** (第 1-2 個月)：收集所有公開的 AI 使用政策、內部備忘錄、倫理指南。若無法取得內部文件，則透過訪談引導受訪者回憶並描述規範內容。2. ****深度訪談**** (第 3-5 個月)：進行半結構式訪談，每次約 90 分鐘。問題大綱包括：- 貴媒體對 GenAI 的具體使用案例(如自動生成財經報導、摘要新聞)。- 規範制定的過程：誰主導？參考了哪些國際例子？有無內部辯論？- 規範在實際執行中的挑戰：記者是否遵守？有無規避行為？- 經濟壓力與專業自主的張力：管理層是否鼓勵 AI 以降低成本？範例提示：「請描述一次您或同事在 AI 使用上遇到倫理困境的情況，以及您如何解決？」、「您認為現行規範最重要的一個缺點是什麼？」3. ****參與式觀察**** (第 6-8 個月)：選取 1-2 家媒體(如一家主流、一家獨立)，以「研究者」身份在編輯室進行為期 2 個月的觀察，每週至少 2 天。記錄日常會議中的 AI 討論、規範執行時的即興協商、以及非正式互動中的規範傳播。這能捕捉到訪談中可能被修飾的「實踐中的規範」。

****三、資料分析**** 採用 Fairclough 的批判論述分析三層次：- 文本層次：分析政策文件中的措辭(如「準確性」vs.「效率」的優先級)、隱含的意識形態(如將 AI 視為工具 vs. 合作者)。- 話語實踐層次：分析訪談中受訪者如何論述規範的正當性，例如引述「全球趨勢」或「讀者信任」來合理化政策。- 社會實踐層次：將規範制度化放在台灣媒體經濟(廣告衰退、點擊率壓力)與政治(政黨偏向)的宏觀脈絡中解釋。

****四、比較架構**** 建立一個「規範強度」指標，包含三個維度：明確性(規範是否具體)、可執行性(有無懲罰機制)、透明度(是否公開)。比較不同媒體的分佈，並連結到其組織特徵(如資金來源、編輯自主權)。這個方法的最大創新在於：它不僅描述規範「是什麼」，還解釋規範「如何被建構」以及「為何有些規範有效，有些無效」。

實驗計畫

****第一階段：文獻回顧與研究設計(第 1-2 個月)**** - 系統性回顧全球 AI 新聞倫理文獻(特別是 Reuters Institute、WAN-IFRA 的報告)，以及台灣相關研究(如目標論文)。- 確定 6 家研究媒體，並取得初步接觸與同意。- 設計訪談大綱與觀察指引，進行試訪(pilot interview)以修正問題。

****第二階段：資料收集（第 3-8 個月）**** - 第 3-5 個月：進行 18-20 場深度訪談（每家 3 人），全程錄音並逐字稿轉錄。同步收集所有公開及內部（經同意）的政策文件。- 第 6-8 個月：在選定的 2 家媒體進行參與式觀察，每天撰寫田野筆記。

****第三階段：資料分析（第 9-12 個月）**** - 使用 NVivo 軟體進行編碼，先以開放式編碼歸納主題（如「經濟邏輯」、「透明度悖論」），再以軸向編碼連結到制度理論概念（如模仿同構、規範壓力）。- 進行跨個案比較：建立矩陣表格，對比 6 家媒體在規範明確性、執行機制、以及從業者知覺的有效性上的差異。- 撰寫分析備忘錄，逐步建構理論模型。

****第四階段：結果驗證與撰寫（第 13-15 個月）**** - 邀請 2-3 名受訪者進行成員檢核（member checking），確認分析詮釋的準確性。- 撰寫論文，結構包含：引言、文獻回顧、方法、四個主要發現章節（如「全球規範的在地翻譯」、「規範的規避與抵抗」、「經濟壓力下的規範妥協」、「獨立媒體的規範先鋒」）、討論與結論。- 目標投稿期刊：《新聞學研究》（TSSCI）或《傳播文化》。

****成功指標****：- 完成所有訪談與觀察，達到資料飽和。- 發現至少 3 個原創性模式（例如：規範的「儀式性採用」現象——媒體發布政策但從未執行）。- 論文獲得審查者肯定其理論貢獻（如對制度理論的新聞室應用）與實務洞見（如提供具體的規範改進建議）。- 若預算允許，舉辦一場工作坊，邀請受訪媒體參與，分享研究成果並促進實務反思。

可信新穎度 — 最接近的真實論文

- Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan's Newsrooms (68.1% · airiti.AL, 2025) — 增量：該論文採用半結構訪談，聚焦於台灣新聞室採用 GenAI 的經濟動機與技術創新，但未深入探討倫理指南的制度化過程。本研究則以多重個案比較設計，結合批判論述分析與參與式觀察，專門分析全球倫理規範如何在台灣新聞室中被翻譯、調適或抵抗，並關注規範從書面政策轉化為日常實踐的動態過程，而非僅止於採用動機。（相似度 68% 偏高，標籤經相似度守衛下修）
- The Application and Development of Artificial Intelligence in Taiwan's News Communication (64.5% · airiti.AL, 2021) — 區隔明確：該論文探討 AI 在台灣新聞傳播的應用對信任與社會真實的侵蝕，並以技術方案（AI 訓練假新聞辨識模型）作為解決方向。本研究則不聚焦於技術解決方案或信任侵蝕的總體效應，而是從制度理論視角，分析倫理指南在組織內部的制度化機制，包括權力動態、在地政治經濟脈絡與編輯室文化，方法上更納入參與式觀察以捕捉實踐中的規範協商。
- AI, Newsroom Automation, and the Configuration of News in Transformation (58.5% · airiti.AL, 2024) — 區隔明確：該論文探討生成式 AI 如何改變新聞生產流程、組織型態與新聞樣貌，屬於宏觀的產業生態變遷分析。本研究則聚焦於微觀的組織制度化過程，比較不同類型新聞媒體（主流商業、獨立非營利、新創數位）如何採用、調適或忽視倫理指南，並透過參與式觀察捕捉日常實踐中的規範協商，而非僅描述自動化帶來的整體衝擊。

參考文獻

1. AI, Newsroom Automation, and the Configuration of News in Transformation
2. Whom Are News Bots " Laboring " for? Effects of Automated Journalism on Journalists
3. Gender Politics in a Non-Mainstream Newsroom: A Case Study of the Shih-Hsin University Publication Newsweek
4. The Practical Orientation for Materializing the Independent Knowledge System of Contemporary Chinese Journalism

5. The Strength and Limitation of AI Embedding News: The Competition for the Professional Power of Journalism between ChatGPT and Journalists from the Perspective of Human-Machine Relationship
6. 2A1-L02 Journalist Robot : Robot System Making News Articles from Real World
7. Generative Artificial Intelligence in News Media: Perceived Risks, Norms, and Practices
8. Tango Under the COVID-19 Infodemic: Taiwan's Practice of and Reflection on Fact-checking Journalism
9. The Application and Development of Artificial Intelligence in Taiwan's News Communication
10. Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan's Newsrooms
11. Consideration of ways to report sport culture
12. Enhancing healthcare efficiency with artificial intelligence: Benefits, challenges, and the future of clinical practice
13. Application of AI in Atmospheric Science
14. Artificial Intelligence, media, and constitutionalism
15. 報道はAIとどう向き合うのか
16. 新聞攝影倫理：悲慘報導中真實性與倫理道德問題的平衡
17. A Philosophical Analysis of AI - generated Works and the Copyright Law of China
18. Opportunities, Challenges and Countermeasures of News Communication in the Era of Artificial Intelligence
19. Guest editorial: Application and research of generative AI in education
20. Ethical Gaps in Journalism Education: How Journalism Students Perceive Journalistic Ethics and Media Performance
21. Taming v.s. Resistance: The Resistance Strategies of Media Professionalism for Chinese Government Political Power
22. Research on the Credibility of Content Broadcasted by AI and Human Anchors
23. A Review of Studies on the Political Effects of Social Media and AI Technologies: Reflecting on the Third Wave of SSS and Code/Space Theory
24. Humanistic News production in the Era of Intelligent Communication: Practical Situation and Theoretical Orientation
25. Implementation and Evaluation of an Interpretable Fake News Detector
26. Exploring Artificial Intelligence Technologies for Fake News Detection
27. Empirical Research on Fake News Detection Using AI Technology

28. Copyright Strategy for AI Generated News from the Perspective of Incentive Theory
29. 利用自然語言處理進行自動新聞分類之研究
30. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
31. 人工智能在美國新聞業的應用與影響
32. 從”人機協同”看人工智慧時代的新聞倫理建構
33. 媒體可信度研究：起源，發展，機會和挑戰
34. 人工智能對新聞業影響的對策分析
35. 汪志堅 | AI 深度學習與假新聞偵測
36. 數據新聞：大數據時代新聞可視化傳播的創新路徑
37. 大數據與新聞報導
38. 大數據方法與新聞傳播創新：從理論定義到操作路線
39. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
40. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
41. 再論後真相：基於時間與速度的視角
42. Post-truth，後真相的真相
43. 誰帶風向：被金錢操弄的公共輿論戰爭
44. 不是臺灣獨有- 大選假新聞成全球流行病

政治脈絡感知之 AI 輔助事實查核系統：以台灣政治假新聞為例

後設資料

想法編號: seed-domain-2=>1=>1=>3

新穎度: 27.2%

最大相似度: 72.8% (近似於: “Empirical Research on Fake News Detection Using AI Technology”)

群集: 1

競賽得分: 1 勝

方法論契合度: 4/5

Methodology Reasoning: Develops an AI system for fake news detection with accuracy evaluation, includes experiment on trust and behavior, and addresses Taiwan political context. Extends target methodology with political context awareness and personalized feedback, but introduces new system design elements.

問題陳述

在台灣，政治假新聞已成為民主社會的重大威脅，尤其伴隨選舉與政治極化，不實訊息快速擴散，侵蝕公眾對媒體與制度的信任。現有事實查核機制（如台灣事實查核中心）雖具權威性，但面臨三大困境：第一，查核速度遠不及假新聞傳播速度，人工查核耗時費力；第二，查核結果常被政治立場極化的使用者質疑或忽略，產生「知覺偏誤」——使用者傾向於相信符合自身立場的訊息，即使查核報告證明其為假；第三，靜態的查核報告（如「錯誤」標籤）無法適應不同政治敏感度的議題，例如涉及政黨核心利益的假新聞需要更深入揭露動機與脈絡，而低敏感度議題則只需簡潔事實陳述。現有 AI 輔助查核系統多專注於分類準確率，忽略政治脈絡與使用者心理因素，導致查核成效有限。本研究旨在開發一個能感知政治脈絡的 AI 輔助事實查核系統，整合高準確率分類器、動態解釋生成模組及使用者模型，以提升查核在政治極化環境中的有效性，並探討其對使用者信任、態度改變及行為意圖的影響。此問題不僅具有學術價值（融合政治傳播、AI 可解釋性、使用者心理學），更具即時社會意義，可為台灣事實查核組織與媒體提供具政治敏感性的工具設計指引。

現有方法

現有事實查核方法主要分為三類：第一，人工查核機制，如台灣事實查核中心、CoFacts 等平台，依賴專家與志工查證，雖具高準確性，但速度慢、成本高，且查核報告常以靜態標籤呈現（如「錯誤」、「部分錯誤」），缺乏針對不同政治立場使用者的個人化設計。第二，AI 假新聞偵測模型，例如基於 BERT、RoBERTa 等預訓練語言模型的分類器，在公開資料集（如 LIAR、PolitiFact）上可達 90% 以上準確率，但多為黑箱模型，缺乏可解釋性，且未考慮台灣特有的政治語境（如「芒果乾」、「抗中保台」等政治俚語）。第三，可解釋 AI (XAI) 方法，如注意力視覺化、LIME、SHAP，或生成自然語言解釋（如 NILE 模型），但這些解釋通常是靜態且通用的，未根據使用者先驗態度或政治敏感度動態調整。此外，現有研究多聚焦於技術層面，忽略使用者心理因素（如確認偏誤、演算法厭惡）對查核接受度的影響。例如，Cheng et al. (2024) 探討可解釋性對態度分歧使用者的影響，但未將其整合到完整的查核系統中。簡言之，現有方法缺乏對政治脈絡的深度感知、個人化解釋生成，以及使用者模型的整合，無法有效應對台灣政治極化下的假新聞挑戰。

研究動機

現有方法為何不足？首先，政治假新聞的本質是高度情境化的：同樣的虛假陳述（如「某候選人涉弊」），在不同政黨支持者眼中可能被視為「真相」或「抹黑」。傳統 AI 分類器僅輸出二元標籤，忽略這種「政治脈絡」，導致查核結果常被視為偏頗。其次，靜態的解釋（如「此訊息不符事實」）無法說服已深陷確認偏誤的使用者；相反，若解釋能根據議題敏感度動態調整——例如對高敏感度議題揭露背後動機（如「此假新聞來自特定陣營的協同操作」），對低敏感度議題僅提供事實對照——則更可能促進態度改變。第三，使用者先驗態度（如對民進黨或國民黨的認同）會影響其對查核結果的接受度。現有系統忽略此點，導致查核效果有限。本研究的靈感來自整合「政治傳播理論」（如審議式報導、框架效應）與「AI 可解釋性」：我們假設一個能感知政治脈絡的系統，通過動態調整解釋框架（如從中立事實陳述到揭露偏誤動機），並根據使用者模型個人化回饋，將比傳統靜態查核更有效。具體而言，本系統借鑒「審議式新聞」中促進公民認知與信任的理念，以及「框架效應」中解釋方式影響接收度的研究，將之應用於 AI 查核。預期此方法能更好地對抗確認偏誤，提升使用者信任與不分享假新聞的行為意圖。

提出方法

本系統架構分為三個核心模組，以下詳述：

模組一：政治脈絡感知之假新聞分類器- **概述**：基於預訓練語言模型（如台灣繁體中文版 BERT、或是多語言 RoBERTa），訓練一個多任務分類器，不僅判斷新聞是否為假，同時預測其政治議題類別（如「民進黨相關」、「國民黨相關」、「無黨派/中立」）與政治敏感度分數（0-1，基於議題爭議性與相關政黨利益）。- **資料集建置**：從台灣事實查核中心、MyGoPen 等平台收集已查核之政治假新聞，並由專家標註：政黨傾向（如攻擊民進黨、攻擊國民黨、跨黨派）、議題類型（如選舉、防疫、兩岸）、敏感度等級。同時收集真實新聞作為負樣本。預估規模：至少 10,000 則。- **模型設計**：使用多頭注意力機制，共享底層 BERT 編碼器，上接三個任務頭：(a) 真假分類頭（binary cross-entropy）；(b) 政治議題分類頭（3 類，使用 softmax）；(c) 敏感度回歸頭（MSE loss）。訓練時採用交替訓練策略，並加入對抗訓練以提高魯棒性。目標：真假分類準確率 > 90%，議題分類準確率 > 85%。

模組二：動態解釋生成模組- **概述**：根據分類器輸出（真假標籤、議題類別、敏感度分數），動態生成自然語言解釋。解釋框架分為三層：(1) 低敏感度：僅提供事實對照（如「此訊息與官方統計不符，正確數據為...」）；(2) 中敏感度：加入來源分析（如「此訊息最早來自某匿名帳號，該帳號過去曾散布不實訊息」）；(3) 高敏感度：揭露動機與脈絡（如「此訊息意在打擊特定候選人，與某陣營的選舉策略一致」）。- **實現方式**：基於序列到序列模型（如 T5 或 GPT-3.5 fine-tuned），輸入為：查核文本、分類結果、敏感度分數、目標框架層級；輸出為自然語言解釋。訓練資料由專家撰寫不同框架的解釋對照，每則假新聞至少 3 種解釋版本。此外，引入「框架切換」機制：若使用者反饋顯示懷疑，系統可自動升級解釋層級（如從低敏感度升至中敏感度）。

模組三：使用者模型與個人化回饋- **概述**：建立一個輕量使用者模型，記錄使用者的過往互動（如點擊、分享、反饋）、政治態度（透過簡短問卷或隱含偏好推斷，如閱讀新聞的政黨傾向），以及對查核結果的信任度。基於此，系統個人化回饋：例如，對強烈支持民進黨的使用者，在解釋中避免直接攻擊其立場，而是以「根據多方證據」的中立口吻呈現。- **實現方式**：使用協同過濾或簡單的規則庫（如「若使用者屬藍營支持者，則對涉及藍營的假新聞解釋採用『證據呈現』而非『動機揭露』」）。同時，系統會定期主動提供「審議式回饋」——邀請使用者對比不同立場的查核報告，以促進反思。

系統流程 1. 使用者輸入或分享一則新聞。2. 分類器輸出真假標籤、議題類別、敏感度分數。3. 模組二根據敏感度與議題生成初始解釋。4. 使用者模型載入該使用者歷史數據，調整解釋語氣與框架（如加入個人化提醒）。5. 回饋呈現後，收集使用者行為與反饋，動態更新使用者模型。

此方法創新之處在於：首次將政治脈絡（政黨傾向、敏感度）作為模型設計核心，而非僅視為噪聲；動態解釋框架在事實查核領域前所未有；使用者模型整合了政治心理學與 AI 互動。

實驗計畫

步驟一：資料集建置與預處理- **來源**：爬取台灣事實查核中心 (2018-2024)、MyGoPen、LINE 訊息查證平台上的政治相關查核報告，共約 5,000 則假新聞，並從四大報（聯合報、自由時報、中國時報、蘋果日報）收集等量真實新聞。- **標註**：聘請 3 位政治學與傳播學研究生進行：政黨傾向（攻擊 DPP/攻擊 KMT/無黨派）、敏感度（1-5 分）、解釋框架撰寫（每則假新聞 3 種解釋版本）。一致性檢驗 (Cohen's Kappa > 0.7)。- **分割**：訓練集 70%、驗證集 15%、測試集 15%。

步驟二：基線模型比較- **基線 1**：傳統 BERT 分類器（僅真假分類，無政治脈絡）。- **基線 2**：BERT + 靜態解釋（使用 LIME 或注意力視覺化）。- **基線 3**：政治脈絡分類器（本系統模組一）但無動態解釋。- **基線 4**：本系統完整版。- **評估指標**：分類準確率、F1 分數；解釋質量：由專家評分（1-5，涵蓋正確性、相關性、說服力）；使用者實驗指標（見步驟三）。

步驟三：使用者實驗- **設計**：2（政治極化程度：高 vs. 低）x 2（使用者先驗態度：支持 DPP vs. 支持 KMT）x 3（回饋類型：傳統查核報告 vs. 靜態 AI 查核 vs. 本系統）混合設計。- **樣本**：招募 300 名台灣公民（透過 SurveyCake 或 PTT），依政治態度分組。- **流程**：每人觀看 10 則政治假新聞（5 則攻擊 DPP、5 則攻擊 KMT），隨機分配至三種回饋條件。觀看後填寫問卷：信任度（1-7 量表）、態度改變（前後測差距）、行為意圖（是否願意分享）。- **假設**：本系統組的信任度與態度改變顯著高於其他組；對高極化使用者，動態解釋框架效果更佳。- **分析**：ANOVA、事後比較。

步驟四：結果與成功標準- **技術成功**：分類器準確率>90%，解釋被專家評分平均>4.0。- **使用者成功**：本系統組對查核結果的信任度顯著高於基線（ $p < 0.05$ ），且態度改變量（Cohen's $d > 0.3$ ）與不分享意圖（行為意圖分數>5.0）較佳。- **發表目標**：投稿至《政治科學論叢》或《傳播與社會學刊》，強調跨域整合與實務貢獻。

可信新穎度 — 最接近的真實論文

- Empirical Research on Fake News Detection Using AI Technology (72.8% · airiti.AL, 2021) — 增量: 該論文僅開發一個新聞可信度評估系統模型，專注於分類準確率 (90.53%)，未處理政治脈絡、使用者心理偏誤或動態解釋生成。本提案則整合政治脈絡感知分類器（含政黨傾向、敏感度預測）、動態解釋模組（依敏感度分層生成解釋）及使用者實驗，探討查核對信任與態度改變的影響，方法與研究問題均更為全面且具政治傳播視角。（相似度 73% 偏高，標籤經相似度守衛下修）
- Exploring Artificial Intelligence Technologies for Fake News Detection (69.9% · airiti.AL, 2021) — 增量: 該論文探討人類與電腦在中文假新聞偵測上的表現，使用 CoFacts 語料及 GPT-2 生成假新聞，重點在分類器效能與人類辨別能力比較。本提案則聚焦於政治脈絡感知的 AI 查核系統，包含動態解釋生成與使用者模型，並針對台灣政治極化環境設計實驗，研究問題從單純偵測轉向提升查核有效性與使用者接受度，差異顯著。（相似度 70% 偏高，標籤經相似度守衛下修）
- The Application and Development of Artificial Intelligence in Taiwan's News Communication (68.1% · airiti.AL, 2021) — 增量: 該論文探討 AI 在台灣新聞傳播的應用，包括生產端、分配端與消費端的影響，並訓練假新聞辨識模型（正確率 90.53%），屬宏觀社會影響分析。本提案則專注於開發一個具政治脈絡感知的 AI 輔助事實查核系統，包含多模組架構（分類器、動態解釋、使用者模型），並進行使用者實驗驗證其效果，研究問題從應用影響轉向系統設計與實證評估，方法與焦點不同。（相似度 68% 偏高，標籤經相似度守衛下修）

參考文獻

1. Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan's Newsrooms
2. Empirical Research on Fake News Detection Using AI Technology

3. Exploring Artificial Intelligence Technologies for Fake News Detection
4. A Survey on Explainable Fake News Detection
5. The Impact of Explainability on Users with Divergent Attitudes in AI-Supported Decision-Making Tasks
6. An Exploratory Study on Deliberative Reporting, Civic Cognitions and Deliberation
7. Research on the Credibility of Content Broadcasted by AI and Human Anchors
8. Anthropomorphic Analysis of Chinese News: A Case Study on Artificial Intelligence Discourse
9. Non-Political Issue, Political Issue and Fact-Checking : An Examination of the Effectiveness of Fact-Checking in Taiwan
10. Exploring practices and competences of fact-checker: A case study of Taiwan FactCheck Center
11. Exploring Fact-Checking Behavior: A Case Study on Food Safety Message
12. Modeling Meta-Explainability of Natural Language Inference
13. A research trend of trust in automation
14. Effects of Algorithm Aversion and Betrayal Aversion on Trust in AI
15. Obstacles and Proposals of Artificial Intelligence News Writing
16. Whom Are News Bots " Laboring " for? Effects of Automated Journalism on Journalists
17. The Application and Development of Artificial Intelligence in Taiwan's News Communication
18. Media Distrust and Fact-Checking as a Means of Journalism Reform: A Case of the Korean Media's Attempt from the Perspective of International Norms
19. Claim Detection in Tweets
20. An Exploratory Study of Development and Usage of an Artificial Intelligence Identification System of News Source Credibility
21. The impact of artificial intelligence news source credibility identification system on the effectiveness of media literacy education
22. Copyright Strategy for AI Generated News from the Perspective of Incentive Theory
23. The Strength and Limitation of AI Embedding News: The Competition for the Professional Power of Journalism between ChatGPT and Journalists from the Perspective of Human-Machine Relationship
24. Historical Changes and Contexts in the Routine of Copy editors in Postwar Japan's Newsrooms: Through the Magazines Published by Nihon Shinbun Kyokai
25. A Study to Investigate Professional Sources and Content Presentations Affecting News Credibility

26. AI, Newsroom Automation, and the Configuration of News in Transformation
27. Trust relationship between audiences and media: “Joui-wei rice event” for a case study
28. Exploring the Linguistic Style Disparities between AI-generated and Manually Written Fact-check Reports: A Case Study on COVID-19 Fake News
29. Toward Automatic Misinformation Detection Utilizing Fact-checked Information
30. Report on the APAC Trusted Media Summit 2023
31. Gendering chatbots by design and its impacts on users trust towards shopping chatbots
32. News Consumption in the Changing Media Landscape 2024 Part I
33. The Wage Levels of Taiwanese Journalists under the Transformation of Technology: The Status Quo and Possible Solutions from a Critical Political Economy Perspective
34. Exploring Advertorials in Television News: Product Placement vs. Professionalism of News Reporting
35. Warrior of Journalism: Further Discussion of Current Journalism Education in Taiwan
36. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
37. 人工智能在美國新聞業的應用與影響
38. 從”人機協同”看人工智慧時代的新聞倫理建構
39. 媒體可信度研究：起源，發展，機會和挑戰
40. 人工智能對新聞業影響的對策分析
41. 汪志堅 | AI 深度學習與假新聞偵測
42. 數據新聞：大數據時代新聞可視化傳播的創新路徑
43. 大數據與新聞報導
44. 大數據方法與新聞傳播創新：從理論定義到操作路線
45. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
46. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
47. 再論後真相：基於時間與速度的視角
48. Post-truth，後真相的真相
49. 誰帶風向：被金錢操弄的公共輿論戰爭
50. 不是臺灣獨有- 大選假新聞成全球流行病

AI輔助查證對台灣記者倫理決策之影響：一項結合可解釋性與工作流程整合的田野實驗

後設資料

想法編號: seed-theory-4=>3=>3=>2

新穎度: 32.5%

最大相似度: 67.5% (近似於: “The Application and Development of Artificial Intelligence in Taiwan’s News Communication”)

群集: 2

競賽得分: 1 勝

方法論契合度: 4/5

Methodology Reasoning: Uses mixed-methods (field trial + qualitative/quantitative data) and focuses on AI in Taiwan news production, directly extending the target’s media trust and AI adoption themes. The field trial with journalists adds a new stakeholder perspective but remains methodologically compatible.

問題陳述

台灣新聞媒體在數位匯流時代面臨嚴重的倫理挑戰，尤其是社群媒體與即時通訊軟體（如 LINE）成為新聞素材的主要來源後，記者為了追求時效性，往往忽略嚴謹的查證程序。根據現有研究（如《數位匯流下的倫理反思與抉擇：台灣電視新聞記者對新媒體素材的使用》），最常見的倫理失誤包括「疏於查證」與「侵犯隱私」。然而，這些研究多為質性訪談，缺少對實際查證行為的量化記錄與干預。此外，現有的 AI 假新聞偵測模型（如 XFlag）雖然能達到高準確率，但這些模型多為黑箱操作，無法提供記者可理解的解釋，導致記者對 AI 建議的信任度低落，甚至產生「自動化偏誤」（automation bias）或「演算法厭惡」（algorithm aversion）。更根本的問題是，這些工具往往獨立於記者的工作流程之外，需要記者主動切換平台進行查詢，增加了認知負擔。因此，本研究的核心問題是：如何設計一個能無縫融入台灣記者工作流程、提供可解釋性驗證建議的 AI 系統，並在真實的產製環境中評估其對記者查證行為、倫理壓力與新聞準確度的影響？這不僅是技術問題，更涉及人機互動、組織社會學與新聞規範的交叉領域，對於重建媒體信任具有關鍵意義。

現有方法

現有方法可歸為三類：第一，自動化事實查核平台（如台灣事實查核中心的 Cofacts、國際的 ClaimBuster），主要針對已發布的公開言論進行比對，但這通常在新聞刊出後才進行，無法預防錯誤。第二，AI 假新聞偵測模型（如 XFlag、FakeBERT），這些模型透過文字特徵、傳播路徑來分類新聞真偽，準確率可達 90% 以上，但它們的解釋往往僅限於注意力權重或特徵重要性列表，對記者來說不夠直觀，且無法處理多模態內容（如影像、影片）。第三，針對記者的查證指南與培訓（如 Google News Initiative 的課程），但這無法解決時間壓力下的即時決策困境。這些方法的共同限制是：(1) 脫離記者實際的產製脈絡（即記者通常在截稿壓力下直接從社群媒體複製內容）；(2) 缺乏對查證行為的過程追蹤（無法知道記者何時進行了查證、查證了哪些面向）；(3) 過於依賴最終結果（真假分類），忽略了查證過程中的倫理權衡（如隱私 vs. 公共利益）；(4) 可解釋性不足，無法建立記者對 AI 的信任，導致工具被棄用。

研究動機

現有方法之所以不足，是因為它們將「查證」視為一個獨立於產製流程的技術問題，而非一個社會認知過程。記者在新聞產製中面對的是動態、多模態且充滿時間壓力的環境。本研究提出的創新在於：將可解釋 AI (XAI) 與工作流程整合設計 (workflow-integrated design) 結合，創造一個「認知夥伴」(cognitive partner) 而非「自動化裁判」。具體動機來自兩個理論：一是認知負荷理論 (Cognitive Load Theory)，認為記者在多工環境下需要降低外部認知負荷，因此 AI 應以最小干擾的方式嵌入既有工具（如編輯系統或即時通訊軟體）。二是可解釋性的「心智模型」理論 (mental model theory)，認為有效的解釋應幫助使用者建立對 AI 行為的預測模型。因此，我們設計的系統不會只給出「真/假」判斷，而是提供多層次的視覺化驗證證據（如來源可信度儀表板、反向圖片搜尋的時間軸、跨事件語意比對的樹狀圖），並允許記者對 AI 的推理進行追問（如「為什麼你認為這個來源可信？」）。這種互動式可解釋性 (interactive XAI) 在先前的研究（如 The Impact of Explainability on Users with Divergent Attitudes）中被證明能提升不同態度使用者的信任。我們認為，這種方法能更有效地改變記者的查證習慣，因為它不僅提供答案，更教導記者如何進行系統性思考，長期下來可內化為職業倫理的一部分。

提出方法

****方法總覽****：本系統命名為「ProofLens」，是一個整合於台灣記者常用工作平台（如 LINE、Slack、或新聞編輯系統 API）的 AI 驗證助手。ProofLens 採用模組化架構，包含四個核心模組：多模態輸入解析器、可信度評估引擎、證據鏈生成器、以及互動式解釋界面。其核心創新在於「反事實解釋」(counterfactual explanation) 與「情境感知提示」(context-aware prompting) 的結合，讓記者不僅知道「這個內容不可信」，還能理解「如果改掉哪些部分，就會可信」。

****步驟一：工作流程嵌入與被動觸發**** ProofLens 以瀏覽器擴充元件或 LINE Bot 形式存在，當記者複製貼上文字或圖片到編輯器時，系統自動被動觸發（不需記者主動開啟）。例如，記者從 Facebook 貼文複製一段文字，系統立即在編輯器側邊欄彈出驗證建議。

****步驟二：多模態內容解析**** 針對文字：使用繁體中文 BERT（如 bert-base-chinese）進行命名實體辨識 (NER) 與事件抽取，識別人物、地點、時間及事件類型。針對圖片：使用 Google Vision API 或自訓練的 CNN 進行反向圖片搜尋與修改痕跡檢測（如 ELA 分析）。針對影片：抽幀後進行場景辨識與文字轉語音 (ASR) 分析。

****步驟三：可信度評估引擎**** 此引擎整合三個來源的分數：1. ****來源信譽****：預先建立台灣常見媒體、政治人物、網紅的可信度資料庫（由專家評分與歷史數據更新）。2. ****內容一致性****：與台灣事實查核中心資料庫 (Cofacts)、重大新聞事件時間軸比對，計算語意相似度（使用 Sentence-BERT）。3. ****傳播路徑分析****：使用 Twitter API 或 Facebook Graph API 追蹤該內容的分享網絡，計算傳播深度與可疑帳號比例。最終產生一個 0-100 的「整體可信度指數」，並以顏色（紅黃綠）顯示。

****步驟四：證據鏈生成與反事實解釋**** 這是最創新的部分。系統自動產生一個視覺化證據鏈，例如：- 文字：顯示原始聲明與來源網站的文章片段，高亮顯示矛盾之處。- 圖片：並列原始圖片與反向搜尋到的最早版本，標示修改區域。- 反事實解釋：例如「如果將『3 萬人參加』改為『現場估計約 2 千人』，可信度將從 30 提升至 85」。這個解釋透過對內容進行局部擾動 (perturbation) 並重新計算可信度來生成。

****步驟五：互動式追問**** 記者可以點擊證據鏈中的任何節點，例如點擊「來源信譽」節點，系統會展開該來源的歷史發布記錄及其過往被查核的結果。記者也可以輸入自然語言問題，如「這個照片有沒有在其他災難中使用過？」，系統會調用跨事件比對模組，顯示類似影像在不同事件中的使用案例。

****步驟六：反饋循環**** 記者最後的查證決策（採用/忽略 AI 建議）會被記錄，並用於微調可信度模型。每週生成一次個人化報告，顯示記者的查證行為變化（如查證次數、採納比例）。

實驗計畫

****實驗設計****：採用混合方法，包含一個 4 週的田野實驗與後續的深度訪談。

****參與者****：從三家台灣主要新聞媒體（例如：TVBS、聯合報、鏡週刊）招募 30 名記者（每家 10 名），涵蓋政治、社會、生活線路。

****階段一：前測（第 1-2 天）**** - 對所有記者進行倫理決策情境測驗（基於《數位匯流下的倫理反思與抉擇》的案例）。- 安裝 ProofLens 瀏覽器擴充元件，但處於隱藏模式（僅記錄背景操作）。

****階段二：控制期（第 1-2 週）**** - 記者照常工作，系統隱藏，但記錄所有記者接觸的社群媒體內容及其後續查證行為（透過螢幕錄製與系統 log）。- 每日隨機收集 30 篇記者產製的新聞，由兩位資深媒體倫理專家（盲審）評分新聞準確度（1-5 分）與倫理得分（基於疏於查證、侵犯隱私等指標）。

****階段三：介入期（第 3-4 週）**** - 啟動 ProofLens 的完整功能。記者會收到系統的即時驗證建議與解釋。- 系統記錄記者與 ProofLens 的互動（如點擊次數、追問次數、採納建議比例）。- 同樣收集每日 30 篇新聞，由相同專家盲審。

****階段四：後測與訪談（第 5 週）**** - 再次進行倫理決策情境測驗。- 進行半結構化深度訪談（每人 30 分鐘），探討記者對 ProofLens 的信任、使用障礙、以及對倫理決策的感知影響。

****評估指標****：1. ****客觀指標****：- 查證行動率（控制期 vs. 介入期，透過 log 計算記者對每個可疑內容的查證次數）- 新聞準確度評分（專家評分的平均差異）- 倫理失誤次數（專家標記的疏於查證或隱私侵犯案例數）2. ****主觀指標****：- 感知倫理壓力（使用修改後的倫理壓力量表，5 點李克特）- 對 AI 的信任（使用自動化系統信任量表，ATS）- 系統可用性（SUS 分數）

****成功標準****：- 介入期查證行動率顯著高於控制期（paired t-test, $p < 0.05$ ）。- 新聞準確度評分平均提升 0.5 分以上。- 倫理失誤次數降低 30% 以上。- 記者對 AI 的信任平均分數高於量表中間值 3 分。

****數據分析****：使用線性混合模型（LMM）控制媒體類型與記者個人差異。質性訪談資料使用主題分析法。

****預期成果****：本研究將證明，一個情境感知且可解釋的 AI 查證工具能有效減少台灣記者的倫理失誤，並提供一個可複製的工作流程整合設計模式，對後續 AI 在新聞倫理教育中的應用具有重要啟發。

可信新穎度 — 最接近的真實論文

- The Application and Development of Artificial Intelligence in Taiwan's News Communication (67.5% · airtiti.AL, 2021) — 增量: 該論文主要探討 AI 在台灣新聞傳播的應用與發展，並訓練假新聞辨識模型，但未涉及將 AI 系統嵌入記者工作流程、提供可解釋性驗證建議，或透過田野實驗量化評估對記者查證行為與倫理決策的影響。本研究則聚焦於人機互動與組織社會學角度，設計可解釋性 AI 助手並進行實地干預實驗。（相似度 67% 偏高，標籤經相似度守衛下修）
- Technological Innovation or Economic Motivation? A Preliminary Study on the Adoption of Generative Artificial Intelligence Technology in Taiwan's Newsrooms (61.7% · airtiti.AL, 2025) — 區隔明確: 該論文採用質化訪談探討台灣新聞室採用生成式 AI（如 ChatGPT）的動機與現狀，未涉及設計 AI 輔助查證系統、提供可解釋性驗證建議，或透過田野實驗量化評估對記者倫理決策的影響。本研究則以量化田野實驗為主，結合可解釋性 AI 與工作流程整合，直接測量查證行為與新聞準確度。
- Empirical Research on Fake News Detection Using AI Technology (61.0% · airtiti.AL, 2021) — 區隔明確: 該論文開發新聞可信度評估系統模型，但未將系統整合至記者工作流程、提供反事實解釋，或透過田野實驗評估對記者查證行為與倫理決策的影響。本研究則聚焦於人機互動與組織社會學，設計可解釋性 AI 助手並在真實產製環境中進行干預實驗。

參考文獻

1. Political Polarization in Taiwan: the Effect of Media Communication on Political Polarization
2. Gendering chatbots by design and its impacts on users trust towards shopping chatbots

3. Exposure to Heterogeneous Information on SNSs and Political Polarization: The Role of Political Persuasion and Selective Avoidance
4. Comparing Polarizing Issues in Asian and African Democracies: Voter Confidence, Electoral Reform, and Polarization in Taiwan and Kenya
5. Ethical Reflection and Decisions in Digital Convergence: The Use of New Media Materials by Taiwanese TV Journalists
6. Blog Author Profiling towards Bias Adjustment(<Special Issue>Trust Assessment of Web Information)
7. On Selection Bias of Web-Based Opinion Research and Its Adjustment(<Special Issue>Trust Assessment of Web Information)
8. Impact on confidence in artificial intelligence by sharing secrets using trust games
9. TV Journalists' Social Media Dependency in Disaster News Verification
10. To Verify or Not To Verify, That is the Question: Newspaper Journalists' Considerations of Daily News Verification
11. How AI Technology Alleviate the Talent Shortage in Taiwan' s News Broadcasting Industry
12. The Application and Development of Artificial Intelligence in Taiwan's News Communication
13. A Preliminary Study on the Narrative Structure of Instagram Story News
14. The Impact of Explainability on Users with Divergent Attitudes in AI-Supported Decision-Making Tasks
15. XFlag: explainable fake news detection model on social media
16. Exploring Artificial Intelligence Technologies for Fake News Detection
17. Exploring Fact-Checking Behavior: A Case Study on Food Safety Message
18. Factors and their effects of precautionary measures and fact-checking behavior toward food-safety misinformation
19. Non-Political Issue, Political Issue and Fact-Checking : An Examination of the Effectiveness of Fact-Checking in Taiwan
20. Ethical Gaps in Journalism Education: How Journalism Students Perceive Journalistic Ethics and Media Performance
21. Empirical Research on Fake News Detection Using AI Technology
22. 媒體素養教育首應導正年輕世代的使用觀念
23. The Damages and Solutions of Fake News
24. Exploring the Effects of Game-Based Learning through the Metaverse and Tabletop Games on Audience Awareness, Verification Behavior, and Intrinsic Motivation: A Case Study on the Issue of Fake News

25. Understanding Important Language Features of Fake News: Word Patterns as Neural Networks Inputs
26. Applying Data Mining Methods to Predict Fake News
27. Fake News Detection: A Graph Neural Network Approach
28. Reference-Guided and Domain-Invariant Late Prompts for Fake News Early Detection
29. Research on Audience Media Literacy Phenomenon under AIGC Communication Mode
30. Fake News Detection Algorithms Comparison and Application of XGBoost, SVM, and NB
31. Comparative Study of Machine Learning Approaches for Detecting Fake News in Arabic Text
32. Fake News Detection based on Paddlepaddle
33. Implementation and Evaluation of an Interpretable Fake News Detector
34. An improved self-training model to detect fake news categories using multi-class classification of unlabeled data: fake news classification with unlabeled data
35. Detecting Rumours on Social Media based on a Robust Language Model with External Features
36. AI, Newsroom Automation, and the Configuration of News in Transformation
37. Who Are They? A Study of Data Journalists in Taiwanese Newsrooms
38. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
39. 人工智能在美國新聞業的應用與影響
40. 從”人機協同”看人工智慧時代的新聞倫理建構
41. 媒體可信度研究：起源，發展，機會和挑戰
42. 人工智能對新聞業影響的對策分析
43. 汪志堅 | AI 深度學習與假新聞偵測
44. 數據新聞：大數據時代新聞可視化傳播的創新路徑
45. 大數據與新聞報導
46. 大數據方法與新聞傳播創新：從理論定義到操作路線
47. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
48. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
49. 再論後真相：基於時間與速度的視角
50. Post-truth，後真相的真相
51. 誰帶風向：被金錢操弄的公共輿論戰爭
52. 不是臺灣獨有- 大選假新聞成全球流行病

不只是黑盒子：以信任校準理論為基礎的互動式可解釋假新聞偵測系統—台灣政治與健康資訊之實證研究

後設資料

想法編號: seed-theory-1=>3=>3=>3

新穎度: 35.4%

最大相似度: 64.6% (近似於: “Empirical Research on Fake News Detection Using AI Technology”)

群集: 5

競賽得分: 1 勝

方法論契合度: 5/5

Methodology Reasoning: Directly extends target’s fake news detection model with explainable AI and user trust study; includes source credibility, content features, and user experiment in Taiwan context.

問題陳述

假新聞 (misinformation) 在台灣的泛濫已對民主政治與公共衛生構成嚴峻威脅。從 2018 年地方選舉的境外勢力干預，到 COVID-19 期間關於疫苗與防疫措施的陰謀論，不實資訊的快速傳播侵蝕了社會信任，並導致了實質的傷害 (如延遲就醫、疫苗覆蓋率低落)。現有的假新聞偵測研究多聚焦於提升模型的自動化辨識準確率 (如目標論文所述，以 AI 模型達到 90.53% 的正確率)。然而，一個深刻但未被正視的問題是：即使模型完美，若使用者不信任或不理解其判斷，則系統的社會效益將大打折扣。

更具體地說，台灣社會存在嚴重的「信任極化」現象：不同政治光譜的群體對同一資訊來源 (如主流媒體、政府機關、特定社群平台) 的信任度天差地別。一個被模型標記為「假」的新聞，在某一群體眼中可能是「被壓迫的真相」。這種情況下，傳統的黑盒子模型 (僅輸出「真/假」標籤) 或單調的可解釋 AI (僅輸出特徵權重列表) 無法跨越認知的鴻溝。此外，現有研究多為一次性、橫斷面的實驗，忽略了使用者與系統互動後的學習效應與長期行為改變。

因此，本研究所要解決的核心問題是：如何設計一個不僅能準確偵測台灣假新聞，還能根據使用者的認知狀態與信任傾向，動態生成個人化解釋的 AI 系統？這個系統能否有效地校準使用者對資訊與 AI 本身的信任，從而提升其長期媒體素養？這個問題的答案將決定 AI 技術是否能從「實驗室中的高準確率」轉化為「真實社會中有效的防禦機制」。

現有方法

現有的假新聞偵測方法主要可分為三類：

1. **內容為基礎的方法 (Content-based)**：這類方法分析新聞文本的語言特徵，如情緒極性 (sentiment)、寫作風格 (style)、可讀性 (readability) 等。例如，探索寫作風格的論文 (Explore the Style for Fake News Detection) 即屬於此類。其限制在於，惡意行為者可以輕易模仿真實新聞的風格，導致特徵容易被繞過。此外，此類方法缺乏對資訊來源與傳播脈絡的考量。

2. **來源為基礎的方法 (Source-based)**：這類方法追蹤資訊來源的可信度，如平台 (Cofacts) 的歷史行為記錄。A Novel Source-Content-Topic Dictionary Model for Misinformation Detection 即結合了來源、內容與主題。此類方法的限制在於，新興來源 (如剛成立的粉專) 缺乏歷史數據，且來源的可信度在台灣的極化環境中可能本身就是爭議點。

3. **可解釋 AI (XAI) 方法**：如 A Survey on Explainable Fake News Detection 所概括，XAI 方法 (LIME、SHAP) 旨在解釋模型的決策。然而，現有的 XAI 應用多為靜態的「產出解釋」，例如

「此新聞被分類為假，因為關鍵詞 X、情緒 Y、來源 Z」。它們忽略了人類認知處理解釋的限制（如認知負荷過載、確認偏誤），也未根據使用者的背景（如政治傾向、教育程度）調整解釋的複雜度與呈現方式。

****這些方法共同的侷限****：它們都將使用者視為被動的解釋接收者，而非主動的學習者。沒有一個現有系統能「校準」使用者對 AI 的信任，即讓使用者對 AI 正確的判斷產生足夠的信任（不過度懷疑），並對 AI 錯誤的判斷保持適度的懷疑（不過度信任）。這正是我提出的方法所要突破的瓶頸。

研究動機

現有方法的不足，根源於一個錯誤的假設：只要提供更多、更準確的資訊（無論是模型準確率或解釋），使用者就會自動形成正確的判斷。心理學與傳播學的研究（如信任校準理論 Adaptive trust calibration and its applications）明確指出，人類的信任形成是一個動態的、基於經驗的校準過程。使用者對 AI 的信任，取決於他們在多次互動中感知到的 AI 可靠性與自己的判斷能力。

因此，我的靈感來自於「個人化學習」與「信任校準理論」的結合。我主張：一個有效的假新聞偵測系統，應該像一個優秀的導師，能夠根據學生的程度（使用者的媒體素養與認知負荷）和既有偏見（信任傾向），提供「恰到好處」的解釋。過於簡單的解釋無法說服專家，過於複雜的解釋則會讓新手困惑。

為什麼這個方法會比現有方法更好？1. ****提升使用者判斷能力（非僅依賴模型）****：透過互動式、個人化的解釋，系統可以逐步訓練使用者自行辨識假新聞的徵兆（如極端情緒、來源可疑），達到長期媒體素養的提升，而非僅在當下接受模型的判決。2. ****跨越信任極化****：對於高度疑慮的使用者，系統可以先提供最客觀、最具證據力的解釋（如來源的公開歷史紀錄），並允許使用者深入探究（如點擊查看原始事實查核報告）。這比直接給出「假」標籤更能降低防衛心。3. ****適應性信任校準****：系統會在使用者每次操作中，隱式地（如滑鼠停留時間、是否點擊深入解釋）或顯式地（如回饋問卷）收集使用者對解釋的理解程度，並動態調整後續解釋的風格與深度。這避免了過度信任或信任不足的問題。

提出方法

本提案的核心是一個名為「信任校準者」（Trust Calibrator, TC）的互動式可解釋假新聞偵測框架。它包含三個模組：(A) 多模態假新聞偵測引擎、(B) 個人化使用者模型、(C) 動態解釋生成器。

(A) 多模態假新聞偵測引擎這是一個整合來源、內容與主題的深度學習模型，類似於 A Novel Source-Content-Topic Dictionary Model 的架構，但進行了改良：- ****來源信用追蹤****：從 Cofacts、台灣事實查核中心等平台，建立一個來源（網站、粉絲專頁、帳號）的歷史可信度分數（0-100），並隨時間衰減。- ****內容特徵****：除了情緒、風格，加入「資訊密度」（claims per sentence）與「跨平台一致性」（同一則訊息在不同平台的文本相似度）。- ****主題建模****：使用 BERT-based 的雙語模型來識別新聞所屬的主題（如選舉、疫苗、自然災害），因為不同主題的假新聞語言模式不同。- ****輸出****：模型不僅輸出「真/假」的機率（ P_{fake} ），還輸出各模組的貢獻分數（如來源信用貢獻度 S、內容異常貢獻度 C、主題異常貢獻度 T）。

(B) 個人化使用者模型這個模組負責建立每位使用者的「認知檔案」：- ****初始評估****：註冊時使用簡短問卷（如政治傾向、媒體使用習慣、對 AI 的態度）。- ****動態追蹤****：在每次互動中，系統記錄使用者的行為：閱讀解釋的時間、是否點擊深入連結、對系統判斷的同意度（顯式回饋）、以及後續對類似新聞的判斷正確率。- ****模型****：使用貝葉斯知識追蹤（Bayesian Knowledge Tracing）來估計使用者對特定假新聞線索（如來源可疑、情緒操弄）的掌握程度。同時，使用信任校準理論中的「任務特徵-人類信心-系統表現」三元組來建模使用者的信任傾向。

(C) 動態解釋生成器這是本提案最創新的部分。它根據 (A) 的輸出與 (B) 的使用者模型，即時生成個人化的解釋。解釋的設計遵從「階梯式複雜度」原則：- ****第 1 層（新手模式）****：僅提供圖標式信賴指標（紅/黃/綠燈），加上一句簡單說明。例如：「☐ 此資訊來源過去有多次不實紀錄」。- ****第 2 層（中級模式）****：提供特徵雷達圖（來源信用、情緒極端度、主題異常度），並以條列式說明。例如：「1. 來源信度僅 20/100（過去一年有 15 次錯誤紀錄）。2. 語言情緒極度負面，偏離該主題的正常報導風格」。- ****第 3 層（專家模式）****：提供 SHAP 值圖表，顯示每個詞句對決策的貢獻，並附上對

比案例（類似的新聞但被判定為真）。例如：「『疫苗導致』這個詞組對假判定的貢獻度為+0.35。相比之下，一篇相似的真的報導使用了『疫苗可能與』。」

****動態調整機制****：系統根據使用者模型的估計，決定初始的解釋層級。如果使用者在閱讀中級解釋後，停留時間過長或反覆查看，系統會自動提升至專家模式。如果使用者表現出困惑（如頻繁點擊「？」按鈕），系統則會退回新手模式並提供更多引導。

****解釋內容的個人化****：對於政治傾向鮮明的使用者，系統會優先使用中立的事實查核連結，避免使用可能引發反感的來源（如特定政治陣營的媒體）。但若使用者持續拒絕接受客觀證據，系統會記錄為「高度偏誤」，並在後續互動中增加「認知反思」提示，例如：「請考慮，如果此資訊的來源相反（例如來自另一方），您是否會同樣相信？」

實驗計畫

步驟一：資料集建置與預處理- ****資料來源****：從 Cofacts、台灣事實查核中心、MyGoPen 等平台，爬取過去三年（2022-2025）已查核的新聞。總計至少 5,000 篇，其中真新聞與假新聞比例為 1:1。- ****標註****：以查核結果為黃金標準。另聘請兩位獨立編碼員（大學以上，媒體素養受訓）對每則新聞進行來源、情緒、主題的三軸編碼，以評估模型特徵的有效性。

步驟二：基線模型與 TC 模型訓練- ****基線模型****：- B1: 純內容模型（BERT 分類器，僅使用新聞文本）。- B2: 純來源模型（基於 Cofacts 歷史分數的邏輯回歸）。- B3: 結合內容+來源的整合模型（無可解釋性）。- B4: 整合模型+靜態 LIME 解釋（對所有使用者輸出相同解釋）。- ****TC 模型****：訓練完整的（A）偵測引擎，並整合（B）與（C）模組。偵測引擎的目標是最小化交叉熵損失。- ****評估指標****：準確率、精確率、召回率、F1 分數。預期 TC 模型的偵測準確率應接近或超過目標論文的 90.53%。

步驟三：使用者研究設計（縱向隨機對照實驗）- ****受試者****：招募 120 名台灣大學生與社會人士（年齡 20-50 歲），隨機分為四組，每組 30 人：- 組別 1（控制組）：使用無解釋的黑盒子模型（B3）。- 組別 2（基線可解釋組）：使用靜態 LIME 解釋（B4）。- 組別 3（TC 固定模式組）：使用 TC 模型但解釋層級固定為中級。- 組別 4（TC 動態模式組）：使用完整的 TC 動態解釋系統。- ****實驗流程****（為期四週，每週三次任務）：1. ****第一週（前測）****：所有組別完成 20 則新聞的判斷（無系統輔助），記錄基準判斷正確率。2. ****第二至三週（介入）****：每組使用各自的系統判斷新聞（每天 10 則）。系統記錄所有互動行為。TC 動態組的解釋會根據前次表現調整。3. ****第四週（後測與移轉測驗）****：所有組別再次獨立判斷 20 則新聞（無系統輔助）。此外，進行「移轉測驗」：判斷與訓練主題不同（如從政治轉到健康）的 10 則新聞，以測試媒體素養的類化效果。- ****問卷****：每次任務後填寫簡短問卷，測量對系統的信任（7 點量表）、感知有用性、以及對解釋的理解程度。

步驟四：資料分析與假設驗證- ****主要假設****：- H1: TC 動態組在後測與移轉測驗的判斷正確率顯著高於其他三組（ANOVA + post-hoc Tukey）。- H2: TC 動態組的信任校準（以「信任-準確率差距」指數衡量）優於其他組，即信任程度與系統真實準確率更匹配。- H3: 解釋的個人化程度（以系統調整次數為指標）與使用者判斷正確率的提升呈正相關。- ****分析工具****：混合效果模型（mixed-effects model）處理重複測量資料。質性分析：對 10 名高分與 10 名低分使用者進行半結構式訪談，了解他們對解釋的感受與說服機制。

成功標準- TC 模型偵測準確率 > 90%，且假陽性率 < 5%。- 使用者實驗中，TC 動態組的後測正確率較前測提升至少 15 個百分點，且效果持續到移轉測驗。- 使用者對 TC 動態組的系統信任顯著高於其他組，且無明顯的過度信任或信任不足現象。

可信新穎度 — 最接近的真實論文

- Empirical Research on Fake News Detection Using AI Technology (64.6% · airiti.AL, 2021)
— 區隔明確：該論文僅開發一個高準確率的黑盒子 AI 偵測模型，並在結尾簡略提及可解釋性與人類自主性問題，但未提出具體解決方案。本提案則以信任校準理論為核心，設計一個能根據使用者認知狀態動態生成個人化解釋的互動式系統，並透過縱向隨機對照實驗驗證其對使用者信任

校準與媒體素養的長期影響。本提案在方法上增加了個人化使用者模型與動態解釋生成器，在數據上納入使用者行為追蹤，在研究角度上從「提升模型準確率」轉向「校準人機信任」，因此研究問題與方法有根本差異。

- A comprehensive review of fake news detection on social media: feature engineering, feature fusion, and future research directions (60.9% · airtiti.AL, 2023) — 區隔明確: 該論文為一篇綜述性文獻回顧，主要整理社群媒體假新聞偵測中的特徵工程與特徵融合技術，並提出未來研究方向。本提案則提出一個具體的、可實作的互動式系統框架，包含多模態偵測引擎、個人化使用者模型與動態解釋生成器，並設計縱向使用者實驗來評估系統效果。本提案的貢獻在於提出一個新的系統設計與實證評估，而非文獻整理，因此研究類型與方法有根本差異。
- Exploring Artificial Intelligence Technologies for Fake News Detection (59.2% · airtiti.AL, 2021) — 區隔明確: 該論文比較人類與電腦在中文假新聞偵測上的表現，使用 Cofacts 語料訓練分類器，並用 GPT-2 生成假新聞測試人類辨別力。本提案則聚焦於如何透過互動式可解釋 AI 系統來校準使用者對資訊與 AI 的信任，而非單純比較人機偵測能力。本提案新增了個人化使用者模型、動態解釋生成器，並採用縱向實驗設計追蹤使用者長期行為改變，在研究問題（從「誰偵測得準」轉向「如何讓使用者信任並學習」）與方法上均有根本差異。

參考文獻

1. The Application and Development of Artificial Intelligence in Taiwan's News Communication
2. How AI Technology Alleviate the Talent Shortage in Taiwan's News Broadcasting Industry
3. In social media we distrust: Investigating hostile media perception of Facebook news content
4. Research on the Credibility of Content Broadcasted by AI and Human Anchors
5. Taking Disclosure Seriously: A Comparative Analysis of the Legal Framework About Online Political Ads Between the U.S. and Taiwan in the Era of AI
6. The Impact of Generative AI Advertising on Consumer Purchase Intention
7. The Legal Regulation of AI Transparency: A Study Centered on Its Application in Bank Credit
8. A Novel Source-Content-Topic Dictionary Model for Misinformation Detection
9. Explore the Style for Fake News Detection
10. A Survey on Explainable Fake News Detection
11. 【論文摘要】智慧型手機接收網路新聞之受眾研究
12. Understanding Audience: Theoretical Innovation of Digital Journalism from the Perspective of Audience Turn
13. Green Consumption Behavior-The Moderating Effects of Negative Messages
14. A research trend of trust in automation
15. Adaptive trust calibration and its applications
16. Trust calibration as rationality for human – AI cooperative decision making

17. How Will Generative Artificial Intelligence Transform Education: An Analysis from the Perspective of Automation
18. Whom Are News Bots " Laboring " for? Effects of Automated Journalism on Journalists
19. The Development and Validation of the Learning Engagement Scale for High School Students' Artificial Intelligence Courses
20. AI, Newsroom Automation, and the Configuration of News in Transformation
21. From Balancing " Skills " and " Principles " to Paradigm Shift-A Case Study of Hong Kong Baptist University in Teaching Journalism and Communication
22. The Paradigm Shift in the Era of Intelligent Communication: Ten Viewpoints on Media Technology Research (2023)
23. Estimation of Human Trust in Automatic Operation
24. 以語言與傳播路徑特徵建置 AI 假新聞辨識系統
25. 人工智能在美國新聞業的應用與影響
26. 從”人機協同”看人工智慧時代的新聞倫理建構
27. 媒體可信度研究：起源，發展，機會和挑戰
28. 人工智能對新聞業影響的對策分析
29. 汪志堅 | AI 深度學習與假新聞偵測
30. 數據新聞：大數據時代新聞可視化傳播的創新路徑
31. 大數據與新聞報導
32. 大數據方法與新聞傳播創新：從理論定義到操作路線
33. 社會化媒體、移動終端、大數據：影響新聞生產的新技術因素
34. 社群網路時代的參與編輯：臺灣小編的新聞再混合與新聞守門過程實踐
35. 再論後真相：基於時間與速度的視角
36. Post-truth，後真相的真相
37. 誰帶風向：被金錢操弄的公共輿論戰爭
38. 不是臺灣獨有- 大選假新聞成全球流行病